Gabarito Questões Computacionais

Tuffy

2026-03-27

Lista 3-10 – Econometria I – 2026

Prof.: André Luiz Pereira Mancha
Monitor: Tuffy Licciardi Issa
Email: tuffy@usp.br
GitHub: https://github.com/Tuffyli

Lista 3

Questão 5)

Vamos começar abrindo a base de dados solicitadas pelo exercício.

```r
# Lembre-se de certificar que o pacote 'wooldridge' esteja instalado e
#carregado para acessar a base de dados 'wage1'.
library(wooldridge)
```

```
## Warning: pacote 'wooldridge' foi compilado no R versão 4.5.2
```

```r
# Carregando a base de dados 'hprice1'
data("hprice1")
# Visualizando as primeiras linhas da base de dados para entender sua estrutura
head(hprice1)
```

```
##     price assess bdrms lotsize sqrft colonial   lprice  lassess llotsize
## 1 300.000  349.1     4    6126  2438        1 5.703783 5.855359 8.720297
## 2 370.000  351.5     3    9903  2076        1 5.913503 5.862210 9.200593
## 3 191.000  217.7     3    5200  1374        0 5.252274 5.383118 8.556414
## 4 195.000  231.8     3    4600  1448        1 5.273000 5.445875 8.433811
## 5 373.000  319.1     4    6095  2514        1 5.921578 5.765504 8.715224
## 6 466.275  414.5     5    8566  2754        1 6.144775 6.027073 9.055556
##     lsqrft
## 1 7.798934
## 2 7.638198
## 3 7.225482
## 4 7.277938
## 5 7.829630
## 6 7.920810
```

- **(a)**

Vamos começar estimando os betas desta regressão utilizando o método de Mínimos Quadrados Ordinários (OLS). Para isso, utilizaremos a função `lm()` do R, que é a função padrão para realizar regressões lineares.

```r
# Estimando a regressão utilizando OLS
out <- lm(price ~ sqrft + bdrms, data = hprice1)

#'Para vizualizar os resultados de forma mais organizada, podemos armazenar
#'o modelo em um objeto e depois usar a função summary() para obter um resumo detalhado
#'dos resultados.

summary(out)
```

```
##
## Call:
## lm(formula = price ~ sqrft + bdrms, data = hprice1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -127.627  -42.876   -7.051   32.589  229.003
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -19.31500   31.04662  -0.622    0.536
## sqrft         0.12844    0.01382   9.291 1.39e-14 ***
## bdrms        15.19819    9.48352   1.603    0.113
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 63.04 on 85 degrees of freedom
## Multiple R-squared:  0.6319, Adjusted R-squared:  0.6233
## F-statistic: 72.96 on 2 and 85 DF,  p-value: < 2.2e-16
```

```r
# Para visualizar os resultados de forma mais organizada, podemos usar o stargazer
library(stargazer)

stargazer(out, type = "text")
```

```
##
## ===============================================
##                         Dependent variable:
##                     ---------------------------
##                                price
## -----------------------------------------------
## sqrft                        0.128***
##                               (0.014)
##
## bdrms                         15.198
##                               (9.484)
##
## Constant                      -19.315
##                              (31.047)
```

```
##
## ---------------------------------------------
## Observations                    88
## R2                             0.632
## Adjusted R2                    0.623
## Residual Std. Error      63.045 (df = 85)
## F Statistic           72.964*** (df = 2; 85)
## =============================================
## Note:               *p<0.1; **p<0.05; ***p<0.01
```

Agora podemos reescrever a regressão substituindo os coeficientes estimados pelos seus valores numéricos.

Chegando em:

$$\widehat{price} = -21.77 + 0.122\, sqrft + 13.85\, bdrms$$

- **(b)**

O aumento estimado do preço de uma casa com um quarto a mais (mantida a área constante) é dado pelo coeficiente da variável `bdrms`, que é 13.85. Isso significa que, em média, uma casa com um quarto a mais tem um preço estimado de US$ 13.850,00 a mais do que uma casa com um quarto a menos, mantendo a área constante.

- **(c)**

O aumento estimado do preço de uma casa com um quarto adicional de 140 pés quadrados é dado pelo coeficiente da variável `sqrft`, que é 0.122 adicionado ao aumento do preço devido ao quarto adicional. O aumento total seria:

$$\text{Aumento total} = 0.122 \times 140 + 13.85 = 17.08 + 13.85 = 30.93$$

Ou se preferir, podemos calcular diretamente utilizando a fórmula da regressão:

$$\widehat{price} = -21.77 + 0.122 \times 140 + 13.85 = -21.77 + 17.08 + 13.85 = 30.93$$

Portanto, o aumento estimado do preço de uma casa com um quarto adicional de 140 pés quadrados é de aproximadamente US$ 30.930,00.

- **(d)**

Para observarmos a porcentagem da variação do preço que é explicada pela área e pelo número de quartos e pela área total, devemos olhar para o valor do R^2 da regressão. O R^2 é uma medida que indica a proporção da variação na variável dependente (preço) que é explicada pelas variáveis independentes (área e número de quartos).

```r
# Obtendo o valor do R² da regressão
r_squared <- summary(out)$r.squared #$r.squared é a forma de acessar o valor
#'do R² a partir do resumo do modelo

#'No R $ é usado para acessar elementos específicos de um objeto, e
#'summary(out) retorna um objeto que contém várias informações sobre a regressão,
#' incluindo o R².

# Exibindo o valor do R²
r_squared
```

```
## [1] 0.6319184
```

Com este resultado podemos concluir que aproximadamente 63,2% da variação no preço das casas é explicada pela área e pelo número de quartos, o que indica que essas variáveis são bastante importantes para explicar as diferenças nos preços das casas na base de dados `hprice1`.

- **(e)**

Dada a casa com `sqrft` = 2438 e `bdrms` = 4, podemos usar a equação da regressão para estimar o preço dessa casa. Substituindo os valores na equação:

$$\widehat{price} = -21.77 + 0.122 \times 2438 + 13.85 \times 4 = -21.77 + 297.436 + 55.4 = 331.066$$

Portanto, o preço estimado para uma casa com 2438 pés quadrados e 4 quartos é de aproximadamente US$ 331.066,00.

- **(f)**

Dado preço de venda da primeira casa foi de US$300.000. Para encontrarmos o resíduo dessa casa, precisamos calcular a diferença entre o preço real e o preço estimado pela regressão. Primeiro, vamos acessar as variáveis `sqrft` e `bdrms` da primeira casa na base de dados para calcular o preço estimado.

```r
# Acessando as variáveis da primeira casa
sqrft_first <- hprice1$sqrft[1] # Área da primeira casa
bdrms_first <- hprice1$bdrms[1] # Número de quartos da primeira casa

# Calculando o preço estimado para a primeira casa
estimated_price_first <- -21.77 + 0.122 * sqrft_first + 13.85 * bdrms_first

# Preço real da primeira casa
real_price_first <- hprice1$price[1]

# Calculando o resíduo
residual_first <- real_price_first - estimated_price_first

# Exibindo o resíduo
residual_first
```

```
## [1] -31.066
```

O resíduo da primeira casa é a diferença entre o preço real e o preço estimado, e representa a parte do preço que não é explicada pelas variáveis `sqrft` e `bdrms` na regressão. Vemos que o resíduo é de aproximadamente -31.066,00, o que indica que o preço real da casa é menor do que o preço estimado pela regressão (superestimado). Isso pode ser devido a outros fatores que não foram incluídos na regressão, como localização, estado de conservação, entre outros.

Portanto, podemos concluir que o comprador acabou pagando mais pela casa do que a precificação do nosso modelo.

Lista 4

Questão 5)