


```
stargazer(mod4_d, type = "text", digits = 4)
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               lpsoda
## -----
## prpblck                      0.1216***
##                               (0.0257)
##
## lincome                      0.0765***
##                               (0.0166)
##
## Constant                    -0.7938***
##                               (0.1794)
##
## -----
## Observations                 401
## R2                          0.0681
## Adjusted R2                 0.0634
## Residual Std. Error         0.0821 (df = 398)
## F Statistic                 14.5405*** (df = 2; 398)
## =====
## Note:                       *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod4_d)
```

```
## (Intercept)    prpblck    lincome
## -0.79376804  0.12158026  0.07651138
```

Em um modelo log-nível, a variação percentual aproximada em `psoda` para um aumento de 0,22 em `prpblck` é:

```
delta_pct <- 100 * coef(mod4_d)["prpblck"] * 0.22
delta_pct
```

```
## prpblck
## 2.674766
```

Logo, a variação percentual estimada é de aproximadamente 2.67%.

- (e)

Agora adicionamos `prppov` ao modelo do item anterior.

```
mod4_e <- lm(lpsoda ~ prpblck + lincome + prppov, data = discrim)
summary(mod4_e)
```

```
##
## Call:
## lm(formula = lpsoda ~ prpblck + lincome + prppov, data = discrim)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.32218 -0.04648  0.00651  0.04272  0.35622
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.46333    0.29371  -4.982 0.00000094 ***
## prpblck      0.07281    0.03068   2.373  0.0181 *
## lincome      0.13696    0.02676   5.119 0.00000048 ***
## prppov       0.38036    0.13279   2.864  0.0044 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.08137 on 397 degrees of freedom
## (9 observations deleted due to missingness)
## Multiple R-squared:  0.08696,    Adjusted R-squared:  0.08006
## F-statistic: 12.6 on 3 and 397 DF,  p-value: 0.00000006917
```

```
stargazer(mod4_e, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      lpsoda
## -----
## prpblck                0.0728**
##                      (0.0307)
##
## lincome                0.1370***
##                      (0.0268)
##
## prppov                0.3804***
##                      (0.1328)
##
## Constant              -1.4633***
##                      (0.2937)
##
## -----
## Observations                401
## R2                        0.0870
## Adjusted R2                0.0801
## Residual Std. Error    0.0814 (df = 397)
## F Statistic           12.6040*** (df = 3; 397)
## =====
## Note:                *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod4_e)
```

```
## (Intercept)      prpblck      lincome      prppov
## -1.46333262  0.07280721  0.13695528  0.38035997
```

O ponto central é comparar os coeficientes de `prpblck` em `mod4_d` e `mod4_e`. Em geral, ao incluir `prppov`, a magnitude de `prpblck` cai, mostrando que parte do efeito anterior refletia diferenças de pobreza entre localidades.

- (f)

```
corr_lincome_prppov <- cor(discrim$lincome, discrim$prppov, use = "complete.obs")
corr_lincome_prppov
```

```
## [1] -0.838467
```

A correlação é fortemente negativa, o que faz sentido: 'áreas com maior renda tendem a ter menor proporção de pessoas abaixo da linha de pobreza.

- (g)

A afirmação está incorreta. Colinearidade alta entre `lincome` e `prppov` pode inflar erros-padrão e reduzir a precisão das estimativas individuais, mas não gera vies de MQO nem obriga a retirar uma das variáveis. Se ambas forem relevantes do ponto de vista teórico, podem permanecer no modelo.

Lista 5

Questão 5)

Agora fazemos o gabarito computacional da Lista 5 usando a base DISCRIM, exatamente como pedido no enunciado da lista.

```
library(wooldridge)
library(stargazer)

options(scipen = 999)
data("discrim")

head(discrim)
```

```
##      psoda pfries pentree wagest nmgrs nregs hrsopen  emp psoda2 pfries2 pentree2
## 1  1.12   1.06   1.02   4.25    3    5   16.0 27.5   1.11   1.11   1.05
## 2  1.06   0.91   0.95   4.75    3    3   16.5 21.5   1.05   0.89   0.95
## 3  1.06   0.91   0.98   4.25    3    5   18.0 30.0   1.05   0.94   0.98
## 4  1.12   1.02   1.06   5.00    4    5   16.0 27.5   1.15   1.05   1.05
## 5  1.12    NA   0.49   5.00    3    3   16.0  5.0   1.04   1.01   0.58
## 6  1.06   0.95   1.01   4.25    4    4   15.0 17.5   1.05   0.94   1.00
##      wagest2 nmgrs2 nregs2 hrsopen2 emp2 compown chain density  crmrte state
## 1    5.05    5    5    15.0 27.0    1    3    4030 0.0528866    1
## 2    5.05    4    3    17.5 24.5    0    1    4030 0.0528866    1
## 3    5.05    4    5    17.5 25.0    0    1   11400 0.0360003    1
## 4    5.05    4    5    16.0  NA    0    3    8345 0.0484232    1
```

```
## 5      5.05      3      3      16.0 12.0      0      1      720 0.0615890      1
## 6      5.05      3      4      15.0 28.0      0      1     4424 0.0334823      1
##      prpblck      prppov      prpncar hseval nstores income county      lpsoda
## 1 0.1711542 0.0365789 0.0788428 148300      3 44534      18 0.11332869
## 2 0.1711542 0.0365789 0.0788428 148300      3 44534      18 0.05826885
## 3 0.0473602 0.0879072 0.2694298 169200      3 41164      12 0.05826885
## 4 0.0528394 0.0591227 0.1366903 171600      3 50366      10 0.11332869
## 5 0.0344800 0.0254145 0.0738020 249100      1 72287      10 0.11332869
## 6 0.0591327 0.0835001 0.1151341 148000      2 44515      18 0.05826885
##      lpfries      lhseval      lincome ldensity NJ BK KFC RR
## 1 0.05826885 11.90699 10.70401 8.301521 1 0 0 1
## 2 -0.09431065 11.90699 10.70401 8.301521 1 1 0 0
## 3 -0.09431065 12.03884 10.62532 9.341369 1 1 0 0
## 4 0.01980261 12.05292 10.82707 9.029418 1 0 0 1
## 5      NA 12.42561 11.18840 6.579251 1 1 0 0
## 6 -0.05129331 11.90497 10.70358 8.394799 1 1 0 0
```

- (a)

Vamos estimar por MQO o modelo pedido:

```
mod5_a <- lm(lpsoda ~ prpblck + lincome + prppov, data = discrim)
stargazer(mod5_a, type = "text", digits = 4)
```

```
##
## =====
##                        Dependent variable:
##                        -----
##                        lpsoda
## -----
## prpblck                0.0728**
##                        (0.0307)
##
## lincome                0.1370***
##                        (0.0268)
##
## prppov                 0.3804***
##                        (0.1328)
##
## Constant              -1.4633***
##                        (0.2937)
##
## -----
## Observations           401
## R2                     0.0870
## Adjusted R2            0.0801
## Residual Std. Error    0.0814 (df = 397)
## F Statistic            12.6040*** (df = 3; 397)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod5_a)
```

```
## (Intercept)      prpblck      lincome      prppov  
## -1.46333262  0.07280721  0.13695528  0.38035997
```

Com isso, a equação estimada pode ser escrita como:

$$\widehat{\log(psoda)} = -1.463 + 0.0728 \text{ prpblck} + 0.137 \text{ lincome} + 0.380 \text{ prppov}$$

Temos $n = 401$ observações e $R^2 \approx 0.087$.

Agora vamos verificar se o intercepto é estatisticamente diferente de zero a 5% e a 1%.

```
coef(summary(mod5_a))["(Intercept)", ]
```

```
##           Estimate      Std. Error      t value      Pr(>|t|)  
## -1.4633326164663  0.2937110706789 -4.9822181134816  0.0000009400129
```

O p-valor bilateral do intercepto é aproximadamente 0.0000009. Portanto, rejeitamos $H_0 : \beta_0 = 0$ tanto a 5% quanto a 1%.

- (b)

Agora calculamos a correlação entre `lincome` e `prppov` e registramos os p-valores das duas variáveis no modelo estimado em (a).

```
cor(discrim$lincome, discrim$prppov, use = "complete.obs")
```

```
## [1] -0.838467
```

```
coef(summary(mod5_a))[c("lincome", "prppov"), c("Estimate", "Std. Error", "Pr(>|t|)")]
```

```
##           Estimate Std. Error      Pr(>|t|)  
## lincome  0.1369553  0.02675545  0.000000480201  
## prppov   0.3803600  0.13279031  0.004400337780
```

A correlação entre `lincome` e `prppov` é aproximadamente -0.8385, isto é, fortemente negativa. Mesmo assim, no modelo do item (a), ambas permanecem estatisticamente significantes:

- p-valor bilateral de `lincome`: 0.0000005;
- p-valor bilateral de `prppov`: 0.0044.
- (c)

O intercepto mede o valor previsto de $\log(psoda)$ quando `prpblck` = 0, `lincome` = 0 e `prppov` = 0. Em particular, `lincome` = 0 significaria `income` = 1, o que não é um valor economicamente plausível para a renda mediana de um CEP. Portanto, embora o intercepto seja estatisticamente diferente de zero, ele não tem interpretação econômica muito interessante neste contexto.


```
##                                (0.0293)
##
## lincome                        -0.0530
##                                (0.0375)
##
## prppov                         0.0521
##                                (0.1345)
##
## lhseval                       0.1213***
##                                (0.0177)
##
## Constant                      -0.8415***
##                                (0.2924)
##
## -----
## Observations                   401
## R2                            0.1839
## Adjusted R2                   0.1757
## Residual Std. Error           0.0770 (df = 396)
## F Statistic                   22.3131*** (df = 4; 396)
## =====
## Note:                         *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod5_e)
```

```
## (Intercept)    prpblck    lincome    prppov    lhseval
## -0.84151492  0.09755017 -0.05299043  0.05212289  0.12130565
```

Com a nova variável, a equação estimada fica:

$$\widehat{\log(psoda)} = -0.842 + 0.0976 \text{ prpblck} - 0.0530 \text{ lincome} + 0.0521 \text{ prppov} + 0.1213 \text{ lhseval}$$

O coeficiente de `lhseval` é aproximadamente 0.1213. Como temos um modelo log-log nessa variável, ele é uma elasticidade: um aumento de 1% no valor das casas da região está associado a um aumento de aproximadamente 0.12% no preço do refrigerante, *ceteris paribus*.

Agora vamos observar o que acontece com a significância individual de `lincome` e `prppov`.

```
coef(summary(mod5_e))[c("lincome", "prppov", "lhseval"), c("Estimate", "Std. Error", "Pr(>|t|)")]
```

```
##           Estimate Std. Error      Pr(>|t|)
## lincome -0.05299043 0.03752608 0.15870700131425639
## prppov   0.05212289 0.13449922 0.69856986191565551
## lhseval  0.12130565 0.01768407 0.00000000002668167
```

Depois da inclusão de `lhseval`, tanto `lincome` quanto `prppov` deixam de ser individualmente significantes aos níveis usuais:

- p-valor de `lincome`: 0.1587;
- p-valor de `prppov`: 0.6986.

Ja lhseval permanece fortemente significativa.

Por fim, vamos testar se lincome e prppov s~ao conjuntamente significativas.

```
mod5_e_restrito <- lm(lpsoda ~ prpblck + lhseval, data = discrim)
anova(mod5_e_restrito, mod5_e)
```

```
## Analysis of Variance Table
##
## Model 1: lpsoda ~ prpblck + lhseval
## Model 2: lpsoda ~ prpblck + lincome + prppov + lhseval
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1     398 2.3911
## 2     396 2.3493  2  0.041797 3.5227 0.03045 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O p-valor do teste F conjunto e aproximadamente 0.03045. Portanto, rejeitamos a hip'otese nula de que os coeficientes de lincome e prppov sejam ambos zero ao nivel de 5%.

Em resumo:

- lincome e prppov n~ao s~ao individualmente significantes depois da inclus~ao de lhseval;
- mas elas s~ao **conjuntamente significativas** a 5%.

Lista 6

Questao 5)

Agora fazemos o gabarito computacional da Lista 6 com os dados WAGE1.

```
library(wooldridge)
library(stargazer)
data("wage1")

head(wage1)
```

```
##   wage educ exper tenure nonwhite female married numdep smsa northcen south
## 1 3.10   11    2     0         0      1      0      2    1         0    0
## 2 3.24   12   22     2         0      1      1      3    1         0    0
## 3 3.00   11    2     0         0      0      0      2    0         0    0
## 4 6.00    8   44    28         0      0      1      0    1         0    0
## 5 5.30   12    7     2         0      0      1      1    0         0    0
## 6 8.75   16    9     8         0      0      1      0    1         0    0
##   west construc ndurman trcommpt trade services profserv profocc clerocc
## 1    1         0      0         0      0         0      0      0      0
## 2    1         0      0         0      0         1      0      0      0
## 3    1         0      0         0      1         0      0      0      0
## 4    1         0      0         0      0         0      0      0      1
## 5    1         0      0         0      0         0      0      0      0
## 6    1         0      0         0      0         0      1      1      0
```



```
##      servocc      lwage expersq tenursq
## 1         0 1.131402         4         0
## 2         1 1.175573        484         4
## 3         0 1.098612         4         0
## 4         0 1.791759       1936       784
## 5         0 1.667707         49         4
## 6         0 2.169054         81        64
```

Vamos definir uma função simples para medir a assimetria dos resíduos.

```
skew_manual <- function(x) {
  m <- mean(x)
  s <- sd(x)
  mean((x - m)^3) / (s^3)
}
```

- (a)

Estimamos a regressão em nível e salvamos os resíduos.

```
mod6_a <- lm(wage ~ educ + exper + tenure, data = wage1)
stargazer(mod6_a, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      wage
## -----
## educ                  0.5990***
##                      (0.0513)
##
## exper                 0.0223*
##                      (0.0121)
##
## tenure               0.1693***
##                      (0.0216)
##
## Constant             -2.8727***
##                      (0.7290)
##
## -----
## Observations          526
## R2                    0.3064
## Adjusted R2           0.3024
## Residual Std. Error   3.0845 (df = 522)
## F Statistic           76.8732*** (df = 3; 522)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod6_a)
```

```
## (Intercept)      educ      exper      tenure  
## -2.87273482  0.59896507  0.02233952  0.16926865
```

Com isso, a equação estimada pode ser escrita como:

$$\widehat{wage} = -2.873 + 0.599 educ + 0.022 exper + 0.169 tenure$$

Logo, mantidos os demais fatores constantes:

- um ano adicional de estudo aumenta o salário horário previsto em aproximadamente US\$ 0,60;
- um ano adicional de experiência aumenta o salário previsto em cerca de US\$ 0,02;
- um ano adicional de tempo no emprego atual aumenta o salário previsto em cerca de US\$ 0,17.


```
res6_a <- resid(mod6_a)  
summary(res6_a)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.  
## -7.6068 -1.7747 -0.6279  0.0000  1.1969 14.6536
```

```
skew_manual(res6_a)
```

```
## [1] 1.55037
```

```
hist(  
  res6_a,  
  breaks = 30,  
  col = "lightblue",  
  border = "white",  
  main = "Resíduos do modelo em nível",  
  xlab = "Resíduo"  
)  
abline(v = 0, col = "red", lwd = 2)
```



No modelo em nível, os res'íduos apresentam assimetria positiva forte. Isso aparece tanto visualmente no histograma quanto na medida de assimetria:

- assimetria aproximada dos res'íduos: 1.55;
- valor m'aximo do res'íduo: 14.654;
- valor m'inimo do res'íduo: -7.607.

Ou seja, h'a uma cauda direita bem mais longa do que a esquerda, o que sugere afastamento da normalidade.

- (b)

Agora repetimos o procedimento com $\log(\text{wage})$ como vari'avel dependente.

```
mod6_b <- lm(lwage ~ educ + exper + tenure, data = wage1)
stargazer(mod6_b, type = "text", digits = 4)
```

```
##
## =====
##               Dependent variable:
##               -----
##               lwage
## -----
## educ                0.0920***
##                   (0.0073)
##
## exper                0.0041**
##                   (0.0017)
##
## tenure              0.0221***
```

```
##                      (0.0031)
##
## Constant              0.2844***
##                      (0.1042)
##
## -----
## Observations           526
## R2                     0.3160
## Adjusted R2            0.3121
## Residual Std. Error    0.4409 (df = 522)
## F Statistic            80.3909*** (df = 3; 522)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod6_b)
```

```
## (Intercept)      educ      exper      tenure
## 0.284359541 0.092028988 0.004121109 0.022067218
```

Agora a equação estimada fica:

$$\widehat{\log(wage)} = 0.284 + 0.092 \text{educ} + 0.004 \text{exper} + 0.022 \text{tenure}$$

Como o modelo é semilog, os coeficientes podem ser lidos aproximadamente como efeitos percentuais:

- um ano adicional de estudo está associado a um salário cerca de 9.2% maior;
- um ano adicional de experiência está associado a um salário cerca de 0.41% maior;
- um ano adicional de tenure está associado a um salário cerca de 2.21% maior.


```
res6_b <- resid(mod6_b)
summary(res6_b)
```

```
##      Min.   1st Qu.   Median     Mean   3rd Qu.     Max.
## -2.05802 -0.29645 -0.03265  0.00000  0.28788  1.42809
```

```
skew_manual(res6_b)
```

```
## [1] 0.02117153
```

```
hist(
  res6_b,
  breaks = 30,
  col = "lightgreen",
  border = "white",
  main = "Resíduos do modelo semilog",
  xlab = "Resíduo"
)
abline(v = 0, col = "red", lwd = 2)
```



Aqui os res'íduos ficam muito mais sim'etricos em torno de zero:

- assimetria aproximada dos res'íduos: 0.021;
- valor m'aximo do res'íduo: 1.428;
- valor m'inimo do res'íduo: -2.058.

Visualmente, o histograma do modelo semilog fica bem mais pr'oximo de uma distribuiç~ao em forma de sino.

- (c)

Comparando os histogramas e as medidas de assimetria, o modelo semilog fica claramente mais pr'oximo de satisfazer a hip'otese RLM.6. No modelo em nivel, a assimetria dos res'íduos e de cerca de 1.55, enquanto no modelo com $\log(\text{wage})$ ela cai para aproximadamente 0.021.

A intuiç~ao econ^omica tamb'em ajuda: sal'arios em nivel costumam ser bastante assim'etricos, com alguns valores muito altos puxando a distribuiç~ao para a direita. Ao tomar log, comprimimos essa cauda longa e obtemos res'íduos mais equilibrados ao redor de zero. Portanto, a melhor resposta para o item (c) e que a hip'otese de normalidade fica mais plaus'ivel no **modelo semilog**.

Lista 7

Questao 5)

Agora resolvemos a Quest~ao computacional da Lista 7 usando a base NBASAL.

```
library(wooldridge)
library(stargazer)

data("nbasal")
head(nbasal)
```

```
##      marr    wage exper age coll games minutes guard forward center points rebounds
## 1      1 1002.5    4 27    4    77   2867     1      0      0    15.5     3.9
## 2      1 2030.0    5 28    4    78   2789     1      0      0    13.3     2.5
## 3      0  650.0    1 25    4    74   1149     0      0      1     5.5     3.3
## 4      0 2030.0    5 28    4    47   1178     0      1      0     7.3     5.1
## 5      0  755.0    3 24    4    82   2096     1      0      0    10.8     4.3
## 6      0 2014.5    9 31    4    82   1971     0      1      0    11.3     4.9
##      assists draft allstar   avgmin   lwage black children expersq agesq marrblck
## 1         4.5    19        0 37.23376 6.910252     1      0      16    729      1
## 2         8.8    28        0 35.75641 7.615791     1      1     25    784      1
## 3         0.2    19        0 15.52703 6.476973     1      0      1    625      0
## 4         1.5     1        0 25.06383 7.615791     1      0     25    784      0
## 5         2.6    24        0 25.56098 6.626718     1      0      9    576      0
## 6         1.5     4        0 24.03658 7.608126     1      0     81    961      0
```

- (i)

Estimamos primeiro a regress~ao de points sobre exper, exper^2 , age e coll.

```
nbasal$exper2 <- nbasal$exper^2 #criando ao invÃfÃs de usar o I() dentro do modelo
mod7_i <- lm(points ~ exper + I(exper^2) + age + coll, data = nbasal)
stargazer(mod7_i, type = "text", digits = 4)
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               points
## -----
## exper                        2.3636***
##                               (0.4055)
##
## I(exper2)                    -0.0770***
##                               (0.0235)
##
## age                          -1.0740***
##                               (0.2951)
##
## coll                         -1.2863***
##                               (0.4506)
##
## Constant                     35.2183***
##                               (6.9867)
## -----
```

```
## Observations                269
## R2                          0.1412
## Adjusted R2                 0.1282
## Residual Std. Error        5.5095 (df = 264)
## F Statistic                10.8518*** (df = 4; 264)
## =====
## Note:                      *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod7_i)
```

```
## (Intercept)      exper  I(exper^2)      age      coll
## 35.21830851  2.36363052 -0.07702687 -1.07395821 -1.28625454
```

Podemos escrever a equação estimada como:

$$\widehat{points} = 35.218 + 2.364 \text{exper} - 0.0770 \text{exper}^2 - 1.074 \text{age} - 1.286 \text{coll}$$

Assim, **exper** tem efeito positivo no início da carreira, mas com retornos decrescentes por causa do termo quadrático negativo. Além disso, **coll** aparece com coeficiente negativo e estatisticamente significativo.

- (ii)

O efeito marginal de **exper** sobre **points** é:

$$\frac{\partial \widehat{points}}{\partial \text{exper}} = \hat{\beta}_1 + 2\hat{\beta}_2 \text{exper}.$$

Logo, o ponto em que um ano adicional de experiência passa a reduzir os pontos por jogo é:

```
turning_point <- -coef(mod7_i)["exper"] / (2 * coef(mod7_i)["I(exper^2)"])
turning_point
```

```
##      exper
## 15.3429
```

Isto é, aproximadamente 15.34 anos de experiência. Isso até faz algum sentido econômico, porque jogadores muito experientes podem passar do auge físico e produtivo. Ainda assim, esse ponto está bem no fim de uma carreira longa na NBA.

- (iii)

O coeficiente negativo de **coll** provavelmente reflete seleção por talento. Jogadores mais talentosos muitas vezes entram mais cedo na NBA, sem permanecer muitos anos na universidade. Portanto, condicional a idade e experiência na liga, mais anos de faculdade podem estar associados a jogadores que demoraram mais para atingir o nível da NBA, o que ajuda a explicar menor pontuação média.

- (iv)

Agora adicionamos **age**² ao modelo.

```
mod7_iv <- lm(points ~ exper + I(exper^2) + age + I(age^2) + coll, data = nbasal)
stargazer(mod7_iv, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      points
## -----
## exper                2.8638***
##                      (0.6127)
##
## I(exper2)            -0.1281**
##                      (0.0524)
##
## age                  -3.9837
##                      (2.6891)
##
## I(age2)              0.0536
##                      (0.0492)
##
## coll                 -1.3126***
##                      (0.4511)
##
## Constant             73.5903**
##                      (35.9334)
##
## -----
## Observations         269
## R2                   0.1451
## Adjusted R2          0.1288
## Residual Std. Error   5.5076 (df = 263)
## F Statistic           8.9245*** (df = 5; 263)
## =====
## Note:                *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod7_iv)
```

```
## (Intercept)      exper I(exper^2)      age      I(age^2)      coll
## 73.59033664  2.86382779 -0.12807230 -3.98369486  0.05355142 -1.31260376
```

O p-valor de age^2 e:

```
coef(summary(mod7_iv))["I(age^2)", "Pr(>|t|)"]
```

```
## [1] 0.2773153
```

Como esse p-valor é aproximadamente 0.2773, não há evidência de que o termo quadrático em `age` seja necessário. Isso sugere que, uma vez controlados experiência e anos de faculdade, a idade não parece ter um efeito curvo separado relevante sobre `points`.

- (v)

Agora estimamos a regressão de $\log(\text{wage})$ sobre points , exper , exper^2 , age e coll .

```
mod7_v <- lm(lwage ~ points + exper + I(exper^2) + age + coll, data = nbasal)
stargazer(mod7_v, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      lwage
## -----
## points                0.0777***
##                      (0.0071)
##
## exper                 0.2178***
##                      (0.0498)
##
## I(exper2)             -0.0071**
##                      (0.0028)
##
## age                   -0.0481
##                      (0.0349)
##
## coll                  -0.0403
##                      (0.0529)
##
## Constant              6.7790***
##                      (0.8454)
##
## -----
## Observations          269
## R2                    0.4878
## Adjusted R2           0.4781
## Residual Std. Error   0.6367 (df = 263)
## F Statistic            50.1009*** (df = 5; 263)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod7_v)
```

```
## (Intercept)      points      exper  I(exper^2)      age      coll
## 6.779038693  0.077729690  0.217844742 -0.007082144 -0.048137473 -0.040270865
```

A equação estimada fica:

$$\widehat{\log(\text{wage})} = 6.779 + 0.0777 \text{ points} + 0.2178 \text{ exper} - 0.00708 \text{ exper}^2 - 0.0481 \text{ age} - 0.0403 \text{ coll}$$

Os resultados sugerem que:

- um ponto adicional por jogo esta associado a um salário cerca de 7.77% maior;
- experiencia tem efeito positivo, mas decrescente;

- age e coll não são individualmente significativos nessa especificação.
- (vi)

Por fim, testamos se age e coll são conjuntamente significativos na regressão do item (v).

```
mod7_vi_restrito <- lm(lwage ~ points + exper + I(exper^2), data = nbasal)
anova(mod7_vi_restrito, mod7_v)
```

```
## Analysis of Variance Table
##
## Model 1: lwage ~ points + exper + I(exper^2)
## Model 2: lwage ~ points + exper + I(exper^2) + age + coll
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      265 107.59
## 2      263 106.63  2   0.96416 1.1891 0.3061
```

O p-valor do teste F conjunto é aproximadamente 0.3061. Portanto, não rejeitamos a hipótese nula de que age e coll sejam conjuntamente iguais a zero.

Isso sugere que, uma vez controlados produtividade (points) e tempo de serviço (exper e exper²), idade e educação não parecem ter efeitos separados estatisticamente detectáveis sobre salário nessa amostra.

Lista 8

Questão 5)

Agora resolvemos a Questão computacional da Lista 8 usando a base SLEEP75.

```
library(wooldridge)
library(stargazer)
library(lmtest)
library(sandwich)

data("sleep75")
head(sleep75)
```

```
##   age black case clerical construc educ earns74 gdhlth inlf leis1 leis2 leis3
## 1  32     0    1         0         0    12      0      0    1  3529  3479  3479
## 2  31     0    2         0         0    14    9500    1    1  2140  2140  2140
## 3  44     0    3         0         0    17   42500    1    1  4595  4505  4227
## 4  30     0    4         0         0    12   42500    1    1  3211  3211  3211
## 5  64     0    5         0         0    14    2500    1    1  4052  4007  4007
## 6  41     0    6         0         0    12      0      1    1  4812  4797  4797
##   smsa  lhrwage  lothinc male marr prot rlxall selfe sleep slpnaps south
## 1    0 1.955861 10.075380    1    1    1   3163    0  3113    3163    0
## 2    0 0.357674  0.000000    1    0    1   2920    1  2920    2920    1
## 3    1 3.021887  0.000000    1    1    0   3038    1  2670    2760    0
## 4    0 2.263844  0.000000    0    1    1   3083    1  3083    3083    0
## 5    0 1.011601  9.328213    1    1    1   3493    0  3448    3493    0
## 6    0 2.957511 10.657280    1    1    1   4078    0  4063    4078    0
```

```
##      spsepay spwrk75 totwrk union worknrm workscnd exper yngkid yrs marr hrwage
## 1         0         0  3438     0    3438         0   14     0    13  7.070004
## 2         0         0  5020     0    5020         0   11     0     0  1.429999
## 3    20000         1   2815     0    2815         0   21     0     0 20.529997
## 4     5000         1   3786     0    3786         0   12     0    12  9.619998
## 5     2400         1   2580     0    2580         0   44     0    33  2.750000
## 6         0         0   1205     0         0    1205   23     0    23 19.249998
##      agesq
## 1    1024
## 2     961
## 3    1936
## 4     900
## 5    4096
## 6    1681
```

- (i)

Vamos estimar a equaç~ao separadamente para homens e mulheres.

```
mod8_h <- lm(sleep ~ totwrk + educ + age + I(age^2) + yngkid,
             data = sleep75, subset = male == 1)
mod8_m <- lm(sleep ~ totwrk + educ + age + I(age^2) + yngkid,
             data = sleep75, subset = male == 0)

stargazer(mod8_h, mod8_m, type = "text", digits = 4,
          column.labels = c("Homens", "Mulheres"))
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               sleep
##                               Homens      Mulheres
##                               (1)         (2)
## -----
## totwrk                -0.1821***      -0.1399***
##                       (0.0245)         (0.0277)
##
## educ                  -13.0524*        -10.2051
##                       (7.4142)         (9.5888)
##
## age                   7.1566           -30.3566
##                       (14.3204)        (18.5309)
##
## I(age2)               -0.0448          0.3679
##                       (0.1684)        (0.2233)
##
## yngkid                60.3802          -118.2826
##                       (59.0228)        (93.1876)
##
## Constant              3,648.2080***    4,238.7290***
##                       (310.0393)       (384.8923)
##
```

```
## -----
## Observations          400          306
## R2                    0.1562        0.0977
## Adjusted R2           0.1455        0.0826
## Residual Std. Error   402.2903 (df = 394)    436.9919 (df = 300)
## F Statistic           14.5901*** (df = 5; 394) 6.4951*** (df = 5; 300)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

Em ambos os grupos, esperamos que `totwrk` tenha efeito negativo sobre `sleep`: mais minutos de trabalho por semana devem reduzir o tempo de sono. A comparação das duas equações permite ver se esse efeito, bem como os efeitos de `educ`, `age` e `yngkid`, mudam muito por gênero.

- (ii)

Agora fazemos o teste de Chow na forma sugerida pelo enunciado: um modelo restrito com os mesmos coeficientes para homens e mulheres, contra um modelo irrestrito com intercepto diferente e todas as interações com `male`.

```
mod8_r <- lm(sleep ~ totwrk + educ + age + I(age^2) + yngkid, data = sleep75)

mod8_u <- lm(
  sleep ~ male + totwrk + educ + age + I(age^2) + yngkid +
    male:totwrk + male:educ + male:age + male:I(age^2) + male:yngkid,
  data = sleep75
)

anova(mod8_r, mod8_u)
```

```
## Analysis of Variance Table
##
## Model 1: sleep ~ totwrk + educ + age + I(age^2) + yngkid
## Model 2: sleep ~ male + totwrk + educ + age + I(age^2) + yngkid + male:totwrk +
##   male:educ + male:age + male:I(age^2) + male:yngkid
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      700 123267451
## 2      694 121052555   6   2214896 2.1164 0.04949 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Aqui o número de restrições é 6: uma para o intercepto e cinco para as inclinações. Assim, os graus de liberdade relevantes são:

- no numerador: 6;
- no denominador: 694.

O p-valor do teste é 0.04949. Portanto, a decisão a 5% vem diretamente desse valor.

- (iii)

Agora permitimos apenas interceptos diferentes e testamos se os termos de interação são conjuntamente significativos.

```
mod8_int <- lm(sleep ~ male + totwrk + educ + age + I(age^2) + yngkid,
               data = sleep75)

anova(mod8_int, mod8_u)

## Analysis of Variance Table
##
## Model 1: sleep ~ male + totwrk + educ + age + I(age^2) + yngkid
## Model 2: sleep ~ male + totwrk + educ + age + I(age^2) + yngkid + male:totwrk +
##         male:educ + male:age + male:I(age^2) + male:yngkid
##   Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1      699 122147777
## 2      694 121052555   5   1095222 1.2558 0.2814
```

Neste caso, o número de restrições é 5, correspondendo as cinco inclinações adicionais. O p-valor do teste é 0.2814.

- (iv)

No item (ii), rejeitamos a hipótese nula de igualdade completa entre as equações de homens e mulheres. No item (iii), não rejeitamos a hipótese nula de que as inclinações sejam iguais entre os grupos.

Portanto, o modelo final deve permitir **apenas interceptos diferentes por gênero**, mantendo as inclinações iguais. Em outras palavras, a especificação escolhida é a do modelo `mod8_int`.

Lista 9

Questão 5)

Agora resolvemos a Questão computacional da Lista 9 com a base CHARITY.

```
library(wooldridge)
library(stargazer)

data("charity")
head(charity)
```

```
##   respond gift resplast weekslast propresp mailsyear giftlast avggift
## 1      0    0         0 143.00000      0.3      2.5      10      10
## 2      0    0         0  65.42857      0.3      2.5      10      10
## 3      0    0         1  13.14286      0.3      2.5      10      10
## 4      0    0         0 120.14286      0.3      2.5      10      10
## 5      1   10         0 103.85714      0.2      2.5      10      10
## 6      0    0         0 129.14285      0.3      2.5      10      10
```

- (i)

Vamos começar estimando o modelo de probabilidade linear com `respond`, `resplast` e `avggift`.

```
mod9_i <- lm(respond ~ resplast + avggift, data = charity)
summary(mod9_i)
```

```
##
## Call:
## lm(formula = respond ~ resplast + avggift, data = charity)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.6565 -0.2854 -0.2836  0.3727  0.7176
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 0.28208796 0.00883789  31.918 <0.0000000000000002 ***
## resplast    0.34366051 0.01499526  22.918 <0.0000000000000002 ***
## avggift     0.00015358 0.00008993   1.708    0.0877 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4623 on 4265 degrees of freedom
## Multiple R-squared:  0.1101, Adjusted R-squared:  0.1097
## F-statistic: 263.8 on 2 and 4265 DF,  p-value: < 0.00000000000000022
```

```
stargazer(mod9_i, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      respond
## -----
## resplast              0.3437***
##                      (0.0150)
##
## avggift               0.0002*
##                      (0.0001)
##
## Constant             0.2821***
##                      (0.0088)
##
## -----
## Observations          4,268
## R2                    0.1101
## Adjusted R2           0.1097
## Residual Std. Error   0.4623 (df = 4265)
## F Statistic           263.7732*** (df = 2; 4265)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod9_i)
```

```
## (Intercept)    resplast    avggift
## 0.2820879585 0.3436605121 0.0001535789
```

O coeficiente de `resplast` mede a diferença na probabilidade de responder a nova correspondência entre quem respondeu e quem não respondeu a correspondência anterior, mantendo `avggift` fixa.

- (ii)

Para avaliar se `avggift` afeta a probabilidade de resposta, basta olhar seu coeficiente e p-valor na regressão acima.

```
coef(summary(mod9_i))["avggift", ]
```

```
##      Estimate      Std. Error      t value      Pr(>|t|)
## 0.00015357893 0.00008992671 1.70782323022 0.08774192063
```

O p-valor de `avggift` é 0.08774, que é não menor que 0,05. Portanto, não rejeitamos a hipótese nula de coeficiente zero e concluímos que `avggift` não é estatisticamente relevante nessa regressão.

- (iii)

Agora adicionamos `propresp`.

```
mod9_iii <- lm(respond ~ resplast + avggift + propresp, data = charity)
summary(mod9_iii)
```

```
##
## Call:
## lm(formula = respond ~ resplast + avggift + propresp, data = charity)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.8616 -0.3057 -0.1539  0.3989  0.9100
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 0.00230403 0.01511794   0.152      0.8789
## resplast    0.09466782 0.01808668   5.234    0.000000174 ***
## avggift     0.00018202 0.00008515   2.138     0.0326 *
## propresp    0.74868437 0.03369275  22.221 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4377 on 4264 degrees of freedom
## Multiple R-squared:  0.2024, Adjusted R-squared:  0.2019
## F-statistic: 360.8 on 3 and 4264 DF,  p-value: < 0.00000000000000022
```

```
stargazer(mod9_iii, type = "text", digits = 4)
```

```
##
## =====
##              Dependent variable:
##      -----
##              respond
```

```
## -----
## resplast          0.0947***
##                  (0.0181)
##
## avggift           0.0002**
##                  (0.0001)
##
## propresp          0.7487***
##                  (0.0337)
##
## Constant          0.0023
##                  (0.0151)
## -----
## Observations      4,268
## R2                 0.2024
## Adjusted R2       0.2019
## Residual Std. Error 0.4377 (df = 4264)
## F Statistic       360.7560*** (df = 3; 4264)
## =====
## Note:              *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod9_iii)
```

```
## (Intercept)      resplast      avggift      propresp
## 0.0023040289 0.0946678166 0.0001820168 0.7486843711
```

Como **propresp** é uma proporção entre 0 e 1, um aumento de uma unidade representa a maior variação possível: passar de nunca responder para sempre responder. Logo, o coeficiente de **propresp** deve ser lido como o efeito total dessa mudança extrema; uma variação de 0,10 em **propresp** corresponde a 10% desse efeito.

- (iv)

Agora comparamos o coeficiente de **resplast** antes e depois da inclusão de **propresp**.

```
c(
  sem_propresp = coef(mod9_i)["resplast"],
  com_propresp = coef(mod9_iii)["resplast"]
)
```

```
## sem_propresp.resplast com_propresp.resplast
##          0.34366051          0.09466782
```

O coeficiente de **resplast** passa de 0.3437 para 0.0947, uma variação de -0.249. Portanto, o efeito de **resplast** diminui após a inclusão de **propresp**, o que faz sentido porque **propresp** absorve parte do histórico de resposta do doador.

- (v)

Por fim, adicionamos **mailyear**.


```
mod9_v <- lm(respond ~ resplast + avggift + propresp + mailsyear, data = charity)
summary(mod9_v)
```

```
##
## Call:
## lm(formula = respond ~ resplast + avggift + propresp + mailsyear,
##     data = charity)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.9159 -0.3233 -0.1081  0.3864  0.9034
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -0.11720066  0.02450879  -4.782 0.000001794292 ***
## resplast     0.09866077  0.01801995   5.475 0.000000046244 ***
## avggift      0.00017001  0.00008481   2.005    0.0451 *
## propresp     0.73071076  0.03367272  21.700 < 0.0000000000000002 ***
## mailsyear    0.06200977  0.01003625   6.179 0.000000000707 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4358 on 4263 degrees of freedom
## Multiple R-squared:  0.2095, Adjusted R-squared:  0.2088
## F-statistic: 282.5 on 4 and 4263 DF,  p-value: < 0.00000000000000022
```

```
stargazer(mod9_v, type = "text", digits = 4)
```

```
##
## =====
##              Dependent variable:
##              -----
##              respond
## -----
## resplast           0.0987***
##                   (0.0180)
##
## avggift            0.0002**
##                   (0.0001)
##
## propresp           0.7307***
##                   (0.0337)
##
## mailsyear          0.0620***
##                   (0.0100)
##
## Constant           -0.1172***
##                   (0.0245)
##
## -----
## Observations              4,268
## R2                        0.2095
```

```
## Adjusted R2                0.2088
## Residual Std. Error      0.4358 (df = 4263)
## F Statistic             282.4696*** (df = 4; 4263)
## =====
## Note:                    *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod9_v)
```

```
##   (Intercept)      resplast      avggift      propresp      mailsyear
## -0.1172006636  0.0986607746  0.0001700147  0.7307107605  0.0620097677
```

O coeficiente estimado de `mailsyear` é 0.062. Portanto, uma correspondência adicional por ano altera a probabilidade prevista de resposta em aproximadamente 6.2 pontos percentuais, mantidas as demais variáveis fixas.

Essa estimativa, porém, não deve ser interpretada como causal. A conclusão objetiva aqui é: `mailsyear` pode estar correlacionada com características não observadas do doador, de modo que seu coeficiente tem interpretação associativa, e não necessariamente causal.