

Gabarito Questoes Computacionais

Tuffy

2026-04-20

Lista 3 a 11 - Econometria I - 2026

Prof.: Andr'e Luiz Pereira Mancha

Monitor: Tuffy Licciardi Issa

Email: tuffy@usp.br

GitHub: <https://github.com/Tuffyli>

Lista 3

Questao 5)

Vamos começar abrindo a base de dados solicitada pelo exercício.

```
library(wooldridge)
library(stargazer)

data("hprice1")
head(hprice1)
```

```
##      price assess bdrms lotsize sqrft colonial    lprice  lassess llotsize
## 1 300.000  349.1     4    6126  2438         1 5.703783 5.855359 8.720297
## 2 370.000  351.5     3    9903  2076         1 5.913503 5.862210 9.200593
## 3 191.000  217.7     3    5200  1374         0 5.252274 5.383118 8.556414
## 4 195.000  231.8     3    4600  1448         1 5.273000 5.445875 8.433811
## 5 373.000  319.1     4    6095  2514         1 5.921578 5.765504 8.715224
## 6 466.275  414.5     5    8566  2754         1 6.144775 6.027073 9.055556
##      lsqrft
## 1 7.798934
## 2 7.638198
## 3 7.225482
## 4 7.277938
## 5 7.829630
## 6 7.920810
```

- (a)

Vamos estimar por MQO a regressão pedida:

```
mod3 <- lm(price ~ sqrft + bdrms, data = hprice1)
summary(mod3)
```

```
##
## Call:
```

```
## lm(formula = price ~ sqrft + bdrms, data = hprice1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -127.627  -42.876   -7.051   32.589  229.003
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -19.31500    31.04662  -0.622   0.536
## sqrft        0.12844     0.01382   9.291 1.39e-14 ***
## bdrms        15.19819     9.48352   1.603   0.113
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 63.04 on 85 degrees of freedom
## Multiple R-squared:  0.6319, Adjusted R-squared:  0.6233
## F-statistic: 72.96 on 2 and 85 DF,  p-value: < 2.2e-16
stargazer(mod3, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      price
## -----
## sqrft                0.1284***
##                      (0.0138)
##
## bdrms                15.1982
##                      (9.4835)
##
## Constant             -19.3150
##                      (31.0466)
##
## -----
## Observations                88
## R2                        0.6319
## Adjusted R2                0.6233
## Residual Std. Error      63.0448 (df = 85)
## F Statistic              72.9635*** (df = 2; 85)
## =====
## Note:                    *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod3)
```

```
## (Intercept)      sqrft      bdrms
## -19.3149958    0.1284362  15.1981910
```

Assim, a equaç~ao estimada fica:

$$\widehat{price} = \hat{\beta}_0 + \hat{\beta}_1 \text{ sqrft} + \hat{\beta}_2 \text{ bdrms}$$

com os coeficientes numericos dados na sa'ida acima.

- (b)

O efeito de um quarto adicional, mantendo a 'area fixa, e dado pelo coeficiente de `bdrms`.

```
coef(mod3) ["bdrms"]
```

```
##      bdrms  
## 15.19819
```

Ou seja, um quarto a mais aumenta o preço previsto em 15.198 mil d'olares, *ceteris paribus*.

- (c)

Se o quarto adicional vier acompanh'ado de 140 pes quadrados extras, o aumento previsto no preço ser'a:

```
delta_price <- 140 * coef(mod3) ["sqrft"] + coef(mod3) ["bdrms"]  
delta_price
```

```
##      sqrft  
## 33.17926
```

Portanto, o aumento estimado e de 33.179 mil d'olares.

- (d)

O percentual da variaç~ao de `price` explicado por `sqrft` e `bdrms` e medido pelo R^2 .

```
summary(mod3)$r.squared
```

```
## [1] 0.6319184
```

Assim, o modelo explica aproximadamente 63.19% da variaç~ao do preço.

- (e)

Para `sqrft` = 2438 e `bdrms` = 4, a previs~ao e:

```
nova_casa <- data.frame(sqrft = 2438, bdrms = 4)  
predict(mod3, newdata = nova_casa)
```

```
##      1  
## 354.6052
```

- (f)

O res'iduo da primeira observacao e o preço observado menos o preço previsto.

```
preco_previsto_1 <- fitted(mod3)[1]  
preco_observado_1 <- hprice1$price[1]  
residuo_1 <- resid(mod3)[1]
```

```
preco_previsto_1
```

```
##      1  
## 354.6052
```

```
preco_observado_1
```

```
## [1] 300  
residuo_1
```

```
##      1  
## -54.60525
```

Se o res'iduo for negativo, o modelo superestimou o preço da casa. Se for positivo, o modelo subestimou.

Lista 4

Questao 5)

Vamos carregar novamente os pacotes e a base usada no exerc'icio.

```
library(wooldridge)
library(stargazer)

options(scipen = 999)
data("discrim")
head(discrim)
```

	psoda	pfries	pentree	wagest	nmgrs	nregs	hrsopen	emp	psoda2	pfries2	pentree2
## 1	1.12	1.06	1.02	4.25	3	5	16.0	27.5	1.11	1.11	1.05
## 2	1.06	0.91	0.95	4.75	3	3	16.5	21.5	1.05	0.89	0.95
## 3	1.06	0.91	0.98	4.25	3	5	18.0	30.0	1.05	0.94	0.98
## 4	1.12	1.02	1.06	5.00	4	5	16.0	27.5	1.15	1.05	1.05
## 5	1.12	NA	0.49	5.00	3	3	16.0	5.0	1.04	1.01	0.58
## 6	1.06	0.95	1.01	4.25	4	4	15.0	17.5	1.05	0.94	1.00

	wagest2	nmgrs2	nregs2	hrsopen2	emp2	compown	chain	density	crmrt	state
## 1	5.05	5	5	15.0	27.0	1	3	4030	0.0528866	1
## 2	5.05	4	3	17.5	24.5	0	1	4030	0.0528866	1
## 3	5.05	4	5	17.5	25.0	0	1	11400	0.0360003	1
## 4	5.05	4	5	16.0	NA	0	3	8345	0.0484232	1
## 5	5.05	3	3	16.0	12.0	0	1	720	0.0615890	1
## 6	5.05	3	4	15.0	28.0	0	1	4424	0.0334823	1

	prpblck	prppov	prpncar	hseval	nstores	income	county	lpsoda
## 1	0.1711542	0.0365789	0.0788428	148300	3	44534	18	0.11332869
## 2	0.1711542	0.0365789	0.0788428	148300	3	44534	18	0.05826885
## 3	0.0473602	0.0879072	0.2694298	169200	3	41164	12	0.05826885
## 4	0.0528394	0.0591227	0.1366903	171600	3	50366	10	0.11332869
## 5	0.0344800	0.0254145	0.0738020	249100	1	72287	10	0.11332869
## 6	0.0591327	0.0835001	0.1151341	148000	2	44515	18	0.05826885

	lpfries	lhseval	lincome	ldensity	NJ	BK	KFC	RR
## 1	0.05826885	11.90699	10.70401	8.301521	1	0	0	1
## 2	-0.09431065	11.90699	10.70401	8.301521	1	1	0	0
## 3	-0.09431065	12.03884	10.62532	9.341369	1	1	0	0
## 4	0.01980261	12.05292	10.82707	9.029418	1	0	0	1
## 5	NA	12.42561	11.18840	6.579251	1	1	0	0
## 6	-0.05129331	11.90497	10.70358	8.394799	1	1	0	0

- (a)

Primeiro, calculamos m'edias e desvios-padr~ao de prpblck e income.

```
mean_prpblck <- mean(discrim$prpblck, na.rm = TRUE)
sd_prpblck <- sd(discrim$prpblck, na.rm = TRUE)

mean_income <- mean(discrim$income, na.rm = TRUE)
sd_income <- sd(discrim$income, na.rm = TRUE)

data.frame(
  variavel = c("prpblck", "income"),
  media = c(mean_prpblck, mean_income),
  desvio_padr~ao = c(sd_prpblck, sd_income)
)
```

```
##   variavel      media desvio_padrao
## 1 prpblck      0.1134864      0.1824165
## 2  income 47053.7848411 13179.2860689
```

prpblck e uma proporção, variando entre 0 e 1. income mede renda familiar mediana em dólares.

- (b)

O enunciado pede a regressão com psoda.

```
mod4_b <- lm(psoda ~ prpblck + income, data = discrim)
summary(mod4_b)
```

```
##
## Call:
## lm(formula = psoda ~ prpblck + income, data = discrim)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.29401 -0.05242  0.00333  0.04231  0.44322
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.9563196258 0.0189920097  50.354 < 0.0000000000000002 ***
## prpblck      0.1149881907 0.0260006361   4.423  0.0000126 ***
## income       0.0000016027 0.0000003618   4.430  0.0000122 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.08611 on 398 degrees of freedom
## (9 observations deleted due to missingness)
## Multiple R-squared:  0.06422, Adjusted R-squared:  0.05952
## F-statistic: 13.66 on 2 and 398 DF, p-value: 0.000001835
```

```
stargazer(mod4_b, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      psoda
## -----
## prpblck                0.1150***
##                      (0.0260)
##
## income                 0.000002***
##                      (0.000000)
##
## Constant              0.9563***
##                      (0.0190)
##
## -----
## Observations                401
## R2                        0.0642
## Adjusted R2                0.0595
## Residual Std. Error      0.0861 (df = 398)
## F Statistic             13.6569*** (df = 2; 398)
```

```
## =====
## Note:          *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod4_b)
```

```
##      (Intercept)      prpblck      income
## 0.956319625816 0.114988190739 0.000001602674
```

Como o modelo esta em nivel-nivel, o coeficiente de `prpblck` mede a variaç~ao em d'olares no preço do refrigerante para um aumento de uma unidade em `prpblck`. Como uma unidade equivale a 100 pontos percentuais, um aumento de 0,10 em `prpblck` implica variaç~ao prevista de:

```
efeito_10pp_psoda <- 0.10 * coef(mod4_b)["prpblck"]
efeito_10pp_psoda
```

```
##      prpblck
## 0.01149882
```

Ou seja, 0.0115 d'olar por refrigerante. Isso permite discutir se o efeito e econ^omicamente grande ou pequeno.

- (c)

Agora estimamos a regress~ao simples de `psoda` sobre `prpblck`.

```
mod4_c <- lm(psoda ~ prpblck, data = discrim)
summary(mod4_c)
```

```
##
## Call:
## lm(formula = psoda ~ prpblck, data = discrim)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.30884 -0.05963  0.01135  0.03206  0.44840
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)  1.03740     0.00519  199.87 < 0.0000000000000002 ***
## prpblck      0.06493     0.02396    2.71      0.00702 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.0881 on 399 degrees of freedom
## (9 observations deleted due to missingness)
## Multiple R-squared:  0.01808,    Adjusted R-squared:  0.01561
## F-statistic: 7.345 on 1 and 399 DF,  p-value: 0.007015
```

```
stargazer(mod4_c, type = "text", digits = 4)
```

```
##
## =====
##              Dependent variable:
##      -----
##              psoda
##      -----
## prpblck              0.0649***
##                  (0.0240)
##
## Constant              1.0374***
```

```
##
## (0.0052)
##
## -----
## Observations      401
## R2                0.0181
## Adjusted R2       0.0156
## Residual Std. Error 0.0881 (df = 399)
## F Statistic       7.3449*** (df = 1; 399)
## =====
## Note:             *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod4_c)
```

```
## (Intercept)      prpblck
## 1.03739915 0.06492687
```

Comparando o coeficiente de prpblck em (b) e (c), vemos como o controle por renda altera o efeito estimado.

- (d)

Agora estimamos o modelo semilog pedido pelo item:

```
mod4_d <- lm(lpsoda ~ prpblck + lincome, data = discrim)
summary(mod4_d)
```

```
##
## Call:
## lm(formula = lpsoda ~ prpblck + lincome, data = discrim)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.33563 -0.04695  0.00658  0.04334  0.35413
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.79377     0.17943  -4.424 0.00001254 ***
## prpblck      0.12158     0.02575   4.722 0.00000324 ***
## lincome      0.07651     0.01660   4.610 0.00000543 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.0821 on 398 degrees of freedom
## (9 observations deleted due to missingness)
## Multiple R-squared:  0.06809,    Adjusted R-squared:  0.06341
## F-statistic: 14.54 on 2 and 398 DF,  p-value: 0.0000008039
```

```
stargazer(mod4_d, type = "text", digits = 4)
```

```
##
## =====
##              Dependent variable:
##              -----
##              lpsoda
## -----
## prpblck      0.1216***
##              (0.0257)
##
## lincome      0.0765***
```

```
## (0.0166)
##
## Constant -0.7938***
## (0.1794)
##
## -----
## Observations 401
## R2 0.0681
## Adjusted R2 0.0634
## Residual Std. Error 0.0821 (df = 398)
## F Statistic 14.5405*** (df = 2; 398)
## =====
## Note: *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod4_d)
```

```
## (Intercept) prpblck lincome
## -0.79376804 0.12158026 0.07651138
```

Em um modelo log-nível, a variação percentual aproximada em `psoda` para um aumento de 0,22 em `prpblck` é:

```
delta_pct <- 100 * coef(mod4_d)["prpblck"] * 0.22
delta_pct
```

```
## prpblck
## 2.674766
```

Logo, a variação percentual estimada é de aproximadamente 2.67%.

- (e)

Agora adicionamos `prppov` ao modelo do item anterior.

```
mod4_e <- lm(lpsoda ~ prpblck + lincome + prppov, data = discrim)
summary(mod4_e)
```

```
##
## Call:
## lm(formula = lpsoda ~ prpblck + lincome + prppov, data = discrim)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.32218 -0.04648  0.00651  0.04272  0.35622
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.46333    0.29371  -4.982 0.00000094 ***
## prpblck      0.07281    0.03068   2.373  0.0181 *
## lincome      0.13696    0.02676   5.119 0.00000048 ***
## prppov       0.38036    0.13279   2.864  0.0044 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.08137 on 397 degrees of freedom
## (9 observations deleted due to missingness)
## Multiple R-squared:  0.08696, Adjusted R-squared:  0.08006
## F-statistic: 12.6 on 3 and 397 DF, p-value: 0.00000006917
```



```
stargazer(mod4_e, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      lpsoda
## -----
## prpblck                0.0728**
##                      (0.0307)
##
## lincome                0.1370***
##                      (0.0268)
##
## prppov                0.3804***
##                      (0.1328)
##
## Constant              -1.4633***
##                      (0.2937)
##
## -----
## Observations           401
## R2                     0.0870
## Adjusted R2            0.0801
## Residual Std. Error    0.0814 (df = 397)
## F Statistic            12.6040*** (df = 3; 397)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod4_e)
```

```
## (Intercept)    prpblck    lincome    prppov
## -1.46333262  0.07280721  0.13695528  0.38035997
```

O ponto central é comparar os coeficientes de `prpblck` em `mod4_d` e `mod4_e`. Em geral, ao incluir `prppov`, a magnitude de `prpblck` cai, mostrando que parte do efeito anterior refletia diferenças de pobreza entre localidades.

- (f)

```
corr_lincome_prppov <- cor(discrim$lincome, discrim$prppov, use = "complete.obs")
corr_lincome_prppov
```

```
## [1] -0.838467
```

A correlação é fortemente negativa, o que faz sentido: 'áreas com maior renda tendem a ter menor proporção de pessoas abaixo da linha de pobreza.

- (g)

A afirmação está incorreta. Colinearidade alta entre `lincome` e `prppov` pode inflar erros-padrão e reduzir a precisão das estimativas individuais, mas não gera vies de MQO nem obriga a retirar uma das variáveis. Se ambas forem relevantes do ponto de vista teórico, podem permanecer no modelo.

Lista 5

Questao 5)

Agora fazemos o gabarito computacional da Lista 5 usando a base DISCRIM, exatamente como pedido no enunciado da lista.

```
library(wooldridge)
library(stargazer)

options(scipen = 999)
data("discrim")

head(discrim)
```

##	psoda	pfries	pentree	wagest	nmgrs	nregs	hrsopen	emp	psoda2	pfries2	pentree2
## 1	1.12	1.06	1.02	4.25	3	5	16.0	27.5	1.11	1.11	1.05
## 2	1.06	0.91	0.95	4.75	3	3	16.5	21.5	1.05	0.89	0.95
## 3	1.06	0.91	0.98	4.25	3	5	18.0	30.0	1.05	0.94	0.98
## 4	1.12	1.02	1.06	5.00	4	5	16.0	27.5	1.15	1.05	1.05
## 5	1.12	NA	0.49	5.00	3	3	16.0	5.0	1.04	1.01	0.58
## 6	1.06	0.95	1.01	4.25	4	4	15.0	17.5	1.05	0.94	1.00

##	wagest2	nmgrs2	nregs2	hrsopen2	emp2	compown	chain	density	crmrte	state
## 1	5.05	5	5	15.0	27.0	1	3	4030	0.0528866	1
## 2	5.05	4	3	17.5	24.5	0	1	4030	0.0528866	1
## 3	5.05	4	5	17.5	25.0	0	1	11400	0.0360003	1
## 4	5.05	4	5	16.0	NA	0	3	8345	0.0484232	1
## 5	5.05	3	3	16.0	12.0	0	1	720	0.0615890	1
## 6	5.05	3	4	15.0	28.0	0	1	4424	0.0334823	1

##	prpblck	prppov	prpncar	hseval	nstores	income	county	lpsoda
## 1	0.1711542	0.0365789	0.0788428	148300	3	44534	18	0.11332869
## 2	0.1711542	0.0365789	0.0788428	148300	3	44534	18	0.05826885
## 3	0.0473602	0.0879072	0.2694298	169200	3	41164	12	0.05826885
## 4	0.0528394	0.0591227	0.1366903	171600	3	50366	10	0.11332869
## 5	0.0344800	0.0254145	0.0738020	249100	1	72287	10	0.11332869
## 6	0.0591327	0.0835001	0.1151341	148000	2	44515	18	0.05826885

##	lpfries	lhseval	lincome	ldensity	NJ	BK	KFC	RR
## 1	0.05826885	11.90699	10.70401	8.301521	1	0	0	1
## 2	-0.09431065	11.90699	10.70401	8.301521	1	1	0	0
## 3	-0.09431065	12.03884	10.62532	9.341369	1	1	0	0
## 4	0.01980261	12.05292	10.82707	9.029418	1	0	0	1
## 5	NA	12.42561	11.18840	6.579251	1	1	0	0
## 6	-0.05129331	11.90497	10.70358	8.394799	1	1	0	0

- (a)

Vamos estimar por MQO o modelo pedido:

```
mod5_a <- lm(lpsoda ~ prpblck + lincome + prppov, data = discrim)
stargazer(mod5_a, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      lpsoda
## -----
```

```
## prpblck          0.0728**
##                  (0.0307)
##
## lincome          0.1370***
##                  (0.0268)
##
## prppov           0.3804***
##                  (0.1328)
##
## Constant         -1.4633***
##                  (0.2937)
##
## -----
## Observations      401
## R2                0.0870
## Adjusted R2       0.0801
## Residual Std. Error 0.0814 (df = 397)
## F Statistic       12.6040*** (df = 3; 397)
## =====
## Note:             *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod5_a)
```

```
## (Intercept)      prpblck      lincome      prppov
## -1.46333262  0.07280721  0.13695528  0.38035997
```

Com isso, a equa~ao estimada pode ser escrita como:

$$\log(\widehat{psoda}) = -1.463 + 0.0728 \text{ prpblck} + 0.137 \text{ lincome} + 0.380 \text{ prppov}$$

Temos $n = 401$ observacoes e $R^2 \approx 0.087$.

Agora vamos verificar se o intercepto e estat'isticamente diferente de zero a 5% e a 1%.

```
coef(summary(mod5_a))["(Intercept)", ]
```

```
##          Estimate      Std. Error      t value      Pr(>|t|)
## -1.4633326164663  0.2937110706789 -4.9822181134816  0.0000009400129
```

O p-valor bilat'eral do intercepto e aproximadamente 0.0000009. Portanto, rejeitamos $H_0 : \beta_0 = 0$ tanto a 5% quanto a 1%.

- (b)

Agora calculamos a correla~ao entre `lincome` e `prppov` e registramos os p-valores das duas vari'aveis no modelo estimado em (a).

```
cor(discrim$lincome, discrim$prppov, use = "complete.obs")
```

```
## [1] -0.838467
```

```
coef(summary(mod5_a))[c("lincome", "prppov"), c("Estimate", "Std. Error", "Pr(>|t|)")]
```

```
##          Estimate Std. Error      Pr(>|t|)
## lincome  0.1369553  0.02675545  0.000000480201
## prppov   0.3803600  0.13279031  0.004400337780
```

A correla~ao entre `lincome` e `prppov` e aproximadamente -0.8385, isto e, fortemente negativa. Mesmo assim, no modelo do item (a), ambas permanecem estat'isticamente significantes:

- p-valor bilat'eral de `lincome`: 0.0000005;
- p-valor bilat'eral de `prppov`: 0.0044.
- (c)

O intercepto mede o valor previsto de $\log(psoda)$ quando `prpbck` = 0, `lincome` = 0 e `prppov` = 0. Em particular, `lincome` = 0 significaria `income` = 1, o que n~ao e um valor econ^omicamente plaus'ivel para a renda m'ediana de um CEP. Portanto, embora o intercepto seja estat'isticamente diferente de zero, ele **n~ao tem interpretacao econ^omica muito interessante** neste contexto.

- (d)

Agora calculamos o p-valor do teste

$$H_0 : \beta_2 = 1 \quad \text{contra} \quad H_1 : \beta_2 < 1,$$

em que β_2 é o coeficiente de `lincome`.

```
beta2_hat <- coef(mod5_a)["lincome"]
se_beta2 <- coef(summary(mod5_a))["lincome", "Std. Error"]
t_beta2 <- (beta2_hat - 1) / se_beta2
pval_beta2 <- pt(t_beta2, df = df.residual(mod5_a))
```

$$\hat{\beta}_2$$

```
##      lincome
## 0.1369553
```

se_beta2

```
## [1] 0.02675545
```

t_beta2

```
##   lincome
## -32.25679
```

pval_beta2

[illegible]

Como a estatística t é aproximadamente -32.257 e o p -valor unilat'eral é pr'aticamente zero, rejeitamos H_0 ao nível de 1%. Ou seja, h'a evidencia fort'issima de que o coeficiente de `lincome` é menor do que 1.

- (e)

Agora adicionamos `log(hseval)` ao modelo:

```
mod5_e <- lm(lpsoda ~ prpblck + lincome + prppov + lhseval, data = discrim)
stargazer(mod5_e, type = "text", digits = 4)
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               lpsoda
## -----
## prpblck                      0.0976***
##                               (0.0293)
##
```

```
## lincome                -0.0530
##                        (0.0375)
##
## prppov                  0.0521
##                        (0.1345)
##
## lhseval                 0.1213***
##                        (0.0177)
##
## Constant               -0.8415***
##                        (0.2924)
##
## -----
## Observations            401
## R2                      0.1839
## Adjusted R2             0.1757
## Residual Std. Error     0.0770 (df = 396)
## F Statistic             22.3131*** (df = 4; 396)
## =====
## Note:                   *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod5_e)
```

```
## (Intercept)    prpblck    lincome    prppov    lhseval
## -0.84151492  0.09755017 -0.05299043  0.05212289  0.12130565
```

Com a nova variável, a equação estimada fica:

$$\widehat{\log(psoda)} = -0.842 + 0.0976 \text{ prpblck} - 0.0530 \text{ lincome} + 0.0521 \text{ prppov} + 0.1213 \text{ lhseval}$$

O coeficiente de *lhseval* é aproximadamente 0.1213. Como temos um modelo log-log nessa variável, ele é uma elasticidade: um aumento de 1% no valor das casas da região está associado a um aumento de aproximadamente 0.12% no preço do refrigerante, *ceteris paribus*.

Agora vamos observar o que acontece com a significância individual de *lincome* e *prppov*.

```
coef(summary(mod5_e))[c("lincome", "prppov", "lhseval"), c("Estimate", "Std. Error", "Pr(>|t|)")]

##           Estimate Std. Error      Pr(>|t|)
## lincome -0.05299043 0.03752608 0.15870700131425639
## prppov   0.05212289 0.13449922 0.69856986191565551
## lhseval  0.12130565 0.01768407 0.00000000002668167
```

Depois da inclusão de *lhseval*, tanto *lincome* quanto *prppov* deixam de ser individualmente significantes aos níveis usuais:

- p-valor de *lincome*: 0.1587;
- p-valor de *prppov*: 0.6986.

Já *lhseval* permanece fortemente significativa.

Por fim, vamos testar se *lincome* e *prppov* são conjuntamente significativas.

```
mod5_e_restrito <- lm(lpsoda ~ prpblck + lhseval, data = discrim)
anova(mod5_e_restrito, mod5_e)
```

```
## Analysis of Variance Table
##
## Model 1: lpsoda ~ prpblck + lhseval
```

```
## Model 2: lpsoda ~ prpblck + lincome + prppov + lhseval
##   Res.Df    RSS Df Sum of Sq      F Pr(>F)
## 1     398 2.3911
## 2     396 2.3493  2  0.041797 3.5227 0.03045 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O p-valor do teste F conjunto é aproximadamente 0.03045. Portanto, rejeitamos a hipótese nula de que os coeficientes de `lincome` e `prppov` sejam ambos zero ao nível de 5%.

Em resumo:

- `lincome` e `prppov` não são individualmente significantes depois da inclusão de `lhseval`;
- mas elas são **conjuntamente significativas** a 5%.

Lista 6

Questão 5)

Agora fazemos o gabarito computacional da Lista 6 com os dados `WAGE1`.

```
library(wooldridge)
library(stargazer)
data("wage1")

head(wage1)
```

```
##   wage educ exper tenure nonwhite female married numdep smsa northcen south
## 1 3.10   11    2      0        0      1      0      2    1          0    0
## 2 3.24   12   22      2        0      1      1      3    1          0    0
## 3 3.00   11    2      0        0      0      0      2    0          0    0
## 4 6.00    8   44     28        0      0      1      0    1          0    0
## 5 5.30   12    7      2        0      0      1      1    0          0    0
## 6 8.75   16    9      8        0      0      1      0    1          0    0
##   west construc ndurman trcommpt trade services profserv profocc clerocc
## 1    1          0      0      0      0      0      0      0      0      0
## 2    1          0      0      0      0      1      0      0      0      0
## 3    1          0      0      0      1      0      0      0      0      0
## 4    1          0      0      0      0      0      0      0      0      1
## 5    1          0      0      0      0      0      0      0      0      0
## 6    1          0      0      0      0      0      1      1      1      0
##   servocc   lwage expersq tenursq
## 1      0 1.131402      4      0
## 2      1 1.175573     484      4
## 3      0 1.098612      4      0
## 4      0 1.791759    1936     784
## 5      0 1.667707      49      4
## 6      0 2.169054      81     64
```

Vamos definir uma função simples para medir a assimetria dos resíduos.

```
skew_manual <- function(x) {
  m <- mean(x)
  s <- sd(x)
  mean((x - m)^3) / (s^3)
}
```

- (a)

Estimamos a regressão em nível e salvamos os resíduos.

```
mod6_a <- lm(wage ~ educ + exper + tenure, data = wage1)
stargazer(mod6_a, type = "text", digits = 4)
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               wage
## -----
## educ                        0.5990***
##                               (0.0513)
##
## exper                       0.0223*
##                               (0.0121)
##
## tenure                     0.1693***
##                               (0.0216)
##
## Constant                   -2.8727***
##                               (0.7290)
##
## -----
## Observations                526
## R2                          0.3064
## Adjusted R2                 0.3024
## Residual Std. Error        3.0845 (df = 522)
## F Statistic                 76.8732*** (df = 3; 522)
## =====
## Note:                       *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod6_a)
```

```
## (Intercept)      educ      exper      tenure
## -2.87273482  0.59896507  0.02233952  0.16926865
```

Com isso, a equação estimada pode ser escrita como:

$$\widehat{wage} = -2.873 + 0.599 educ + 0.022 exper + 0.169 tenure$$

Logo, mantidos os demais fatores constantes:

- um ano adicional de estudo aumenta o salário horário previsto em aproximadamente US\$ 0,60;
- um ano adicional de experiência aumenta o salário previsto em cerca de US\$ 0,02;
- um ano adicional de tempo no emprego atual aumenta o salário previsto em cerca de US\$ 0,17.


```
res6_a <- resid(mod6_a)
summary(res6_a)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -7.6068 -1.7747 -0.6279  0.0000  1.1969 14.6536
```

```
skew_manual(res6_a)
```

```
## [1] 1.55037
```

```
hist(
  res6_a,
  breaks = 30,
  col = "lightblue",
  border = "white",
  main = "Resíduos do modelo em nível",
  xlab = "Residuo"
)
abline(v = 0, col = "red", lwd = 2)
```



No modelo em nível, os res'íduos apresentam assimetria positiva forte. Isso aparece tanto visualmente no histograma quanto na medida de assimetria:

- assimetria aproximada dos res'íduos: 1.55;
- valor m'aximo do res'íduo: 14.654;
- valor m'inimo do res'íduo: -7.607.

Ou seja, h'a uma cauda direita bem mais longa do que a esquerda, o que sugere afastamento da normalidade.

- (b)

Agora repetimos o procedimento com $\log(\text{wage})$ como vari'avel dependente.

```
mod6_b <- lm(lwage ~ educ + exper + tenure, data = wage1)
stargazer(mod6_b, type = "text", digits = 4)
```

```
##
## =====
##               Dependent variable:
##               -----
##               lwage
## -----
## educ               0.0920***
```



```
## (0.0073)
##
## exper 0.0041**
## (0.0017)
##
## tenure 0.0221***
## (0.0031)
##
## Constant 0.2844***
## (0.1042)
##
## -----
## Observations 526
## R2 0.3160
## Adjusted R2 0.3121
## Residual Std. Error 0.4409 (df = 522)
## F Statistic 80.3909*** (df = 3; 522)
## =====
## Note: *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod6_b)
```

```
## (Intercept) educ exper tenure
## 0.284359541 0.092028988 0.004121109 0.022067218
```

Agora a equação estimada fica:

$$\widehat{\log(wage)} = 0.284 + 0.092 educ + 0.004 exper + 0.022 tenure$$

Como o modelo é semilog, os coeficientes podem ser lidos aproximadamente como efeitos percentuais:

- um ano adicional de estudo está associado a um salário cerca de 9.2% maior;
- um ano adicional de experiência está associado a um salário cerca de 0.41% maior;
- um ano adicional de tenure está associado a um salário cerca de 2.21% maior.

```
res6_b <- resid(mod6_b)
summary(res6_b)
```


```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
## -2.05802 -0.29645 -0.03265 0.00000 0.28788 1.42809
```

```
skew_manual(res6_b)
```

```
## [1] 0.02117153
```

```
hist(
  res6_b,
  breaks = 30,
  col = "lightgreen",
  border = "white",
  main = "Resíduos do modelo semilog",
  xlab = "Resíduo"
)
abline(v = 0, col = "red", lwd = 2)
```

Resíduos do modelo semilog



Aqui os res'íduos ficam muito mais sim'etricos em torno de zero:

- assimetria aproximada dos res'íduos: 0.021;
- valor m'aximo do res'íduo: 1.428;
- valor m'inimo do res'íduo: -2.058.

Visualmente, o histograma do modelo semilog fica bem mais pr'oximo de uma distribuiç~ao em forma de sino.

- (c)

Comparando os histogramas e as medidas de assimetria, o modelo semilog fica claramente mais pr'oximo de satisfazer a hip'otese RLM.6. No modelo em nivel, a assimetria dos res'íduos e de cerca de 1.55, enquanto no modelo com $\log(\text{wage})$ ela cai para aproximadamente 0.021.

A intuiç~ao econ^omica tamb'em ajuda: sal'arios em nivel costumam ser bastante assim'etricos, com alguns valores muito altos puxando a distribuiç~ao para a direita. Ao tomar log, comprimimos essa cauda longa e obtemos res'íduos mais equilibrados ao redor de zero. Portanto, a melhor resposta para o item (c) e que a hip'otese de normalidade fica mais plaus'ivel no **modelo semilog**.

Lista 7

Questao 5)

Agora resolvemos a Quest~ao computacional da Lista 7 usando a base NBASAL.

```
library(wooldridge)
library(stargazer)

data("nbasal")
head(nbasal)
```

```
##   marr   wage exper age coll games minutes guard forward center points rebounds
## 1    1 1002.5    4  27    4    77   2867     1      0      0   15.5      3.9
## 2    1 2030.0    5  28    4    78   2789     1      0      0   13.3      2.5
```

```
## 3    0 650.0    1 25    4 74    1149    0    0    1    5.5    3.3
## 4    0 2030.0   5 28    4 47    1178    0    1    0    7.3    5.1
## 5    0 755.0    3 24    4 82    2096    1    0    0   10.8    4.3
## 6    0 2014.5   9 31    4 82    1971    0    1    0   11.3    4.9
##   assists draft allstar   avgmin   lwage black children expersq agesq marrblck
## 1     4.5    19        0 37.23376 6.910252    1        0     16    729        1
## 2     8.8    28        0 35.75641 7.615791    1        1     25    784        1
## 3     0.2    19        0 15.52703 6.476973    1        0      1    625        0
## 4     1.5     1        0 25.06383 7.615791    1        0     25    784        0
## 5     2.6    24        0 25.56098 6.626718    1        0      9    576        0
## 6     1.5     4        0 24.03658 7.608126    1        0     81    961        0
```

- (i)

Estimamos primeiro a regressão de points sobre exper, exper^2 , age e coll.

```
nbasal$exper2 <- nbasal$exper^2 #criando as invÃfÃes de usar o I() dentro do modelo
```

```
mod7_i <- lm(points ~ exper + I(exper^2) + age + coll, data = nbasal)
stargazer(mod7_i, type = "text", digits = 4)
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               points
## -----
## exper                        2.3636***
##                               (0.4055)
##
## I(exper2)                    -0.0770***
##                               (0.0235)
##
## age                         -1.0740***
##                               (0.2951)
##
## coll                        -1.2863***
##                               (0.4506)
##
## Constant                    35.2183***
##                               (6.9867)
##
## -----
## Observations                 269
## R2                           0.1412
## Adjusted R2                  0.1282
## Residual Std. Error         5.5095 (df = 264)
## F Statistic                 10.8518*** (df = 4; 264)
## =====
## Note:                        *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod7_i)
```

```
## (Intercept)    exper  I(exper^2)      age      coll
## 35.21830851  2.36363052 -0.07702687 -1.07395821 -1.28625454
```

Podemos escrever a equação estimada como:

$$\widehat{points} = 35.218 + 2.364\,exper - 0.0770\,exper^2 - 1.074\,age - 1.286\,coll$$

Assim, **exper** tem efeito positivo no início da carreira, mas com retornos decrescentes por causa do termo quadrático negativo. Além disso, **coll** aparece com coeficiente negativo e estatisticamente significativo.

- (ii)

O efeito marginal de **exper** sobre **points** é:

$$\frac{\partial \widehat{points}}{\partial exper} = \hat{\beta}_1 + 2\hat{\beta}_2\,exper.$$

Logo, o ponto em que um ano adicional de experiência passa a reduzir os pontos por jogo é:

```
turning_point <- -coef(mod7_iv)["exper"] / (2 * coef(mod7_iv)["I(exper^2)"])
turning_point
```

```
## exper
## 15.3429
```

Isto é, aproximadamente 15.34 anos de experiência. Isso até faz algum sentido econômico, porque jogadores muito experientes podem passar do auge físico e produtivo. Ainda assim, esse ponto está bem no fim de uma carreira longa na NBA.

- (iii)

O coeficiente negativo de **coll** provavelmente reflete seleção por talento. Jogadores mais talentosos muitas vezes entram mais cedo na NBA, sem permanecer muitos anos na universidade. Portanto, condicional à idade e experiência na liga, mais anos de faculdade podem estar associados a jogadores que demoraram mais para atingir o nível da NBA, o que ajuda a explicar menor pontuação média.

- (iv)

Agora adicionamos age^2 ao modelo.

```
mod7_iv <- lm(points ~ exper + I(exper^2) + age + I(age^2) + coll, data = nbasal)
stargazer(mod7_iv, type = "text", digits = 4)
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               points
## -----
## exper                        2.8638***
##                               (0.6127)
##
## I(exper2)                    -0.1281**
##                               (0.0524)
##
## age                          -3.9837
##                               (2.6891)
##
## I(age2)                      0.0536
##                               (0.0492)
##
## coll                         -1.3126***
##                               (0.4511)
```

```
##
## Constant                73.5903**
##                        (35.9334)
##
## -----
## Observations                269
## R2                        0.1451
## Adjusted R2                0.1288
## Residual Std. Error      5.5076 (df = 263)
## F Statistic              8.9245*** (df = 5; 263)
## =====
## Note:                    *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod7_iv)
```

```
## (Intercept)      exper  I(exper^2)      age      I(age^2)      coll
## 73.59033664  2.86382779 -0.12807230 -3.98369486  0.05355142 -1.31260376
```

O p-valor de age^2 e:

```
coef(summary(mod7_iv))["I(age^2)", "Pr(>|t|)"]
```

```
## [1] 0.2773153
```

Como esse p-valor é aproximadamente 0.2773, não há evidência de que o termo quadrático em `age` seja necessário. Isso sugere que, uma vez controlados experiência e anos de faculdade, a idade não parece ter um efeito curvo separado relevante sobre `points`.

- (v)

Agora estimamos a regressão de $\log(\text{wage})$ sobre `points`, `exper`, `exper^2`, `age` e `coll`.

```
mod7_v <- lm(lwage ~ points + exper + I(exper^2) + age + coll, data = nbasal)
stargazer(mod7_v, type = "text", digits = 4)
```

```
##
## =====
##                        Dependent variable:
##                        -----
##                        lwage
## -----
## points                0.0777***
##                        (0.0071)
##
## exper                 0.2178***
##                        (0.0498)
##
## I(exper2)             -0.0071**
##                        (0.0028)
##
## age                   -0.0481
##                        (0.0349)
##
## coll                  -0.0403
##                        (0.0529)
##
## Constant              6.7790***
##                        (0.8454)
```

```
##
## -----
## Observations                269
## R2                          0.4878
## Adjusted R2                 0.4781
## Residual Std. Error        0.6367 (df = 263)
## F Statistic                 50.1009*** (df = 5; 263)
## =====
## Note:                       *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod7_v)
```

```
## (Intercept)      points      exper  I(exper^2)      age      coll
## 6.779038693 0.077729690 0.217844742 -0.007082144 -0.048137473 -0.040270865
```

A equaç~ao estimada fica:

$$\widehat{\log(wage)} = 6.779 + 0.0777 points + 0.2178 exper - 0.00708 exper^2 - 0.0481 age - 0.0403 coll$$

Os resultados sugerem que:

- um ponto adicional por jogo esta associado a um sal'ario cerca de 7.77% maior;
- experiencia tem efeito positivo, mas decrescente;
- age e coll n~ao s~ao individualmente significativos nessa especificaç~ao.
- (vi)

Por fim, testamos se age e coll s~ao conjuntamente significativos na regress~ao do item (v).

```
mod7_vi_restrito <- lm(lwage ~ points + exper + I(exper^2), data = nbasal)
anova(mod7_vi_restrito, mod7_v)
```

```
## Analysis of Variance Table
##
## Model 1: lwage ~ points + exper + I(exper^2)
## Model 2: lwage ~ points + exper + I(exper^2) + age + coll
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      265 107.59
## 2      263 106.63  2   0.96416 1.1891 0.3061
```

O p-valor do teste F conjunto e aproximadamente 0.3061. Portanto, n~ao rejeitamos a hip'otese nula de que age e coll sejam conjuntamente iguais a zero.

Isso sugere que, uma vez controlados produtividade (points) e tempo de serviço (exper e exper^2), idade e educaç~ao n~ao parecem ter efeitos separados estat'isticamente detect'aveis sobre sal'ario nessa amostra.

Lista 8

Questao 5)

Agora resolvemos a Quest~ao computacional da Lista 8 usando a base SLEEP75.

```
library(wooldridge)
library(stargazer)
library(lmtest)
library(sandwich)
```

```
data("sleep75")
head(sleep75)
```

```
##   age black case clerical construc educ earns74 gdhlth inlf leis1 leis2 leis3
## 1  32     0   1       0         0   12      0      0    1  3529  3479  3479
## 2  31     0   2       0         0   14    9500    1    1  2140  2140  2140
## 3  44     0   3       0         0   17   42500    1    1  4595  4505  4227
## 4  30     0   4       0         0   12   42500    1    1  3211  3211  3211
## 5  64     0   5       0         0   14    2500    1    1  4052  4007  4007
## 6  41     0   6       0         0   12      0      1    1  4812  4797  4797
##   smsa  lhrwage  lothinc male marr prot rlxall selfe sleep slpnaps south
## 1    0 1.955861 10.075380  1    1    1   3163    0  3113   3163    0
## 2    0 0.357674  0.000000  1    0    1   2920    1  2920   2920    1
## 3    1 3.021887  0.000000  1    1    0   3038    1  2670   2760    0
## 4    0 2.263844  0.000000  0    1    1   3083    1  3083   3083    0
## 5    0 1.011601  9.328213  1    1    1   3493    0  3448   3493    0
## 6    0 2.957511 10.657280  1    1    1   4078    0  4063   4078    0
##   spsepay spwrk75 totwrk union worknrm worksnd exper yngkid yrs marr hrwage
## 1         0         0   3438    0   3438      0   14      0      13 7.070004
## 2         0         0   5020    0   5020      0   11      0      0 1.429999
## 3    20000         1   2815    0   2815      0   21      0      0 20.529997
## 4     5000         1   3786    0   3786      0   12      0      12  9.619998
## 5     2400         1   2580    0   2580      0   44      0      33  2.750000
## 6         0         0   1205    0      0    1205   23      0      23 19.249998
##   agesq
## 1  1024
## 2   961
## 3  1936
## 4   900
## 5  4096
## 6 1681
```

- (i)

Vamos estimar a equaç~ao separadamente para homens e mulheres.

```
mod8_h <- lm(sleep ~ totwrk + educ + age + I(age^2) + yngkid,
             data = sleep75, subset = male == 1)
mod8_m <- lm(sleep ~ totwrk + educ + age + I(age^2) + yngkid,
             data = sleep75, subset = male == 0)

stargazer(mod8_h, mod8_m, type = "text", digits = 4,
          column.labels = c("Homens", "Mulheres"))
```

```
##
## =====
##                               Dependent variable:
##                               -----
##                               sleep
##                               Homens           Mulheres
##                               (1)             (2)
## -----
## totwrk                        -0.1821***      -0.1399***
##                               (0.0245)         (0.0277)
##
```

```
## educ                -13.0524*                -10.2051
##                    (7.4142)                (9.5888)
##
## age                 7.1566                 -30.3566
##                    (14.3204)                (18.5309)
##
## I(age2)             -0.0448                 0.3679
##                    (0.1684)                (0.2233)
##
## yngkid              60.3802                 -118.2826
##                    (59.0228)                (93.1876)
##
## Constant            3,648.2080***           4,238.7290***
##                    (310.0393)            (384.8923)
##
## -----
## Observations        400                    306
## R2                  0.1562                    0.0977
## Adjusted R2         0.1455                    0.0826
## Residual Std. Error 402.2903 (df = 394)      436.9919 (df = 300)
## F Statistic        14.5901*** (df = 5; 394)  6.4951*** (df = 5; 300)
## =====
## Note:                                *p<0.1; **p<0.05; ***p<0.01
```

Em ambos os grupos, esperamos que `totwrk` tenha efeito negativo sobre `sleep`: mais minutos de trabalho por semana devem reduzir o tempo de sono. A comparação das duas equações permite ver se esse efeito, bem como os efeitos de `educ`, `age` e `yngkid`, mudam muito por gênero.

- (ii)

Agora fazemos o teste de Chow na forma sugerida pelo enunciado: um modelo restrito com os mesmos coeficientes para homens e mulheres, contra um modelo irrestrito com intercepto diferente e todas as interações com `male`.

```
mod8_r <- lm(sleep ~ totwrk + educ + age + I(age^2) + yngkid, data = sleep75)

mod8_u <- lm(
  sleep ~ male + totwrk + educ + age + I(age^2) + yngkid +
    male:totwrk + male:educ + male:age + male:I(age^2) + male:yngkid,
  data = sleep75
)

anova(mod8_r, mod8_u)
```

```
## Analysis of Variance Table
##
## Model 1: sleep ~ totwrk + educ + age + I(age^2) + yngkid
## Model 2: sleep ~ male + totwrk + educ + age + I(age^2) + yngkid + male:totwrk +
##   male:educ + male:age + male:I(age^2) + male:yngkid
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      700 123267451
## 2      694 121052555   6   2214896 2.1164 0.04949 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Aqui o número de restrições é 6: uma para o intercepto e cinco para as inclinações. Assim, os graus de liberdade relevantes são:

- no numerador: 6;
- no denominador: 694.

O p-valor do teste é 0.04949. Portanto, a decisão a 5% vem diretamente desse valor.

- (iii)

Agora permitimos apenas interceptos diferentes e testamos se os termos de interação são conjuntamente significativos.

```
mod8_int <- lm(sleep ~ male + totwrk + educ + age + I(age^2) + yngkid,
               data = sleep75)

anova(mod8_int, mod8_u)

## Analysis of Variance Table
##
## Model 1: sleep ~ male + totwrk + educ + age + I(age^2) + yngkid
## Model 2: sleep ~ male + totwrk + educ + age + I(age^2) + yngkid + male:totwrk +
##          male:educ + male:age + male:I(age^2) + male:yngkid
##   Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1      699 122147777
## 2      694 121052555   5   1095222 1.2558 0.2814
```

Neste caso, o número de restrições é 5, correspondendo as cinco inclinações adicionais. O p-valor do teste é 0.2814.

- (iv)

No item (ii), rejeitamos a hipótese nula de igualdade completa entre as equações de homens e mulheres. No item (iii), não rejeitamos a hipótese nula de que as inclinações sejam iguais entre os grupos.

Portanto, o modelo final deve permitir **apenas interceptos diferentes por gênero**, mantendo as inclinações iguais. Em outras palavras, a especificação escolhida é a do modelo `mod8_int`.

Lista 9

Questão 5)

Agora resolvemos a Questão computacional da Lista 9 com a base CHARITY.

```
library(wooldridge)
library(stargazer)

data("charity")
head(charity)

##   respond gift resplast weekslast propresp mailsyear giftlast avggift
## 1      0    0         0 143.00000      0.3      2.5      10      10
## 2      0    0         0  65.42857      0.3      2.5      10      10
## 3      0    0         1  13.14286      0.3      2.5      10      10
## 4      0    0         0 120.14286      0.3      2.5      10      10
## 5      1   10         0 103.85714      0.2      2.5      10      10
## 6      0    0         0 129.14285      0.3      2.5      10      10
```

- (i)

Vamos começar estimando o modelo de probabilidade linear com `respond`, `resplast` e `avggift`.

```
mod9_i <- lm(respond ~ resplast + avggift, data = charity)
summary(mod9_i)
```

```
##
## Call:
## lm(formula = respond ~ resplast + avggift, data = charity)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.6565 -0.2854 -0.2836  0.3727  0.7176
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 0.28208796 0.00883789  31.918 <0.0000000000000002 ***
## resplast    0.34366051 0.01499526  22.918 <0.0000000000000002 ***
## avggift      0.00015358 0.00008993   1.708    0.0877 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4623 on 4265 degrees of freedom
## Multiple R-squared:  0.1101, Adjusted R-squared:  0.1097
## F-statistic: 263.8 on 2 and 4265 DF,  p-value: < 0.00000000000000022
```

```
stargazer(mod9_i, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      respond
## -----
## resplast                0.3437***
##                        (0.0150)
##
## avggift                 0.0002*
##                        (0.0001)
##
## Constant                0.2821***
##                        (0.0088)
##
## -----
## Observations                4,268
## R2                        0.1101
## Adjusted R2                0.1097
## Residual Std. Error      0.4623 (df = 4265)
## F Statistic             263.7732*** (df = 2; 4265)
## =====
## Note:                    *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod9_i)
```

```
## (Intercept)    resplast    avggift
## 0.2820879585 0.3436605121 0.0001535789
```

O coeficiente de **resplast** mede a diferença na probabilidade de responder a nova correspondência entre quem respondeu e quem não respondeu a correspondência anterior, mantendo **avggift** fixa.

- (ii)

Para avaliar se avggift afeta a probabilidade de resposta, basta olhar seu coeficiente e p-valor na regressão acima.

```
coef(summary(mod9_i))["avggift", ]
```

```
##      Estimate      Std. Error      t value      Pr(>|t|)
## 0.00015357893 0.00008992671 1.70782323022 0.08774192063
```

O p-valor de avggift é 0.08774, que é não menor que 0,05. Portanto, não rejeitamos a hipótese nula de coeficiente zero e concluímos que avggift não é estatisticamente relevante nessa regressão.

- (iii)

Agora adicionamos propresp.

```
mod9_iii <- lm(respond ~ resplast + avggift + propresp, data = charity)
summary(mod9_iii)
```

```
##
## Call:
## lm(formula = respond ~ resplast + avggift + propresp, data = charity)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.8616 -0.3057 -0.1539  0.3989  0.9100
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 0.00230403 0.01511794   0.152      0.8789
## resplast    0.09466782 0.01808668   5.234    0.000000174 ***
## avggift     0.00018202 0.00008515   2.138     0.0326 *
## propresp    0.74868437 0.03369275  22.221 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4377 on 4264 degrees of freedom
## Multiple R-squared:  0.2024, Adjusted R-squared:  0.2019
## F-statistic: 360.8 on 3 and 4264 DF,  p-value: < 0.00000000000000022
```

```
stargazer(mod9_iii, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      respond
## -----
## resplast              0.0947***
##                      (0.0181)
##
## avggift               0.0002**
##                      (0.0001)
##
## propresp              0.7487***
##                      (0.0337)
##
```

```
## Constant                0.0023
##                          (0.0151)
## -----
## Observations            4,268
## R2                      0.2024
## Adjusted R2             0.2019
## Residual Std. Error     0.4377 (df = 4264)
## F Statistic             360.7560*** (df = 3; 4264)
## =====
## Note:                   *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod9_iii)
```

```
## (Intercept)    resplast    avggift    propresp
## 0.0023040289 0.0946678166 0.0001820168 0.7486843711
```

Como `propresp` é uma proporção entre 0 e 1, um aumento de uma unidade representa a maior variação possível: passar de nunca responder para sempre responder. Logo, o coeficiente de `propresp` deve ser lido como o efeito total dessa mudança extrema; uma variação de 0,10 em `propresp` corresponde a 10% desse efeito.

- (iv)

Agora comparamos o coeficiente de `resplast` antes e depois da inclusão de `propresp`.

```
c(
  sem_propresp = coef(mod9_i)["resplast"],
  com_propresp = coef(mod9_iii)["resplast"]
)
```

```
## sem_propresp.resplast com_propresp.resplast
##          0.34366051          0.09466782
```

O coeficiente de `resplast` passa de 0.3437 para 0.0947, uma variação de -0.249. Portanto, o efeito de `resplast` diminui após a inclusão de `propresp`, o que faz sentido porque `propresp` absorve parte do histórico de resposta do doador.

- (v)

Por fim, adicionamos `mailsyar`.

```
mod9_v <- lm(respond ~ resplast + avggift + propresp + mailsyear, data = charity)
summary(mod9_v)
```

```
##
## Call:
## lm(formula = respond ~ resplast + avggift + propresp + mailsyear,
##     data = charity)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.9159 -0.3233 -0.1081  0.3864  0.9034
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -0.1172066  0.02450879  -4.782 0.000001794292 ***
## resplast     0.09866077  0.01801995   5.475 0.000000046244 ***
## avggift      0.00017001  0.00008481   2.005    0.0451 *
```

```
## propresp      0.73071076  0.03367272  21.700 < 0.0000000000000002 ***
## mailsyear     0.06200977  0.01003625   6.179      0.000000000707 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4358 on 4263 degrees of freedom
## Multiple R-squared:  0.2095, Adjusted R-squared:  0.2088
## F-statistic: 282.5 on 4 and 4263 DF,  p-value: < 0.00000000000000022
stargazer(mod9_v, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      respond
## -----
## resplast            0.0987***
##                      (0.0180)
##
## avggift             0.0002**
##                      (0.0001)
##
## propresp            0.7307***
##                      (0.0337)
##
## mailsyear           0.0620***
##                      (0.0100)
##
## Constant            -0.1172***
##                      (0.0245)
##
## -----
## Observations        4,268
## R2                   0.2095
## Adjusted R2         0.2088
## Residual Std. Error  0.4358 (df = 4263)
## F Statistic         282.4696*** (df = 4; 4263)
## =====
## Note:                *p<0.1; **p<0.05; ***p<0.01
```

```
coef(mod9_v)

##      (Intercept)      resplast      avggift      propresp      mailsyear
## -0.1172006636  0.0986607746  0.0001700147  0.7307107605  0.0620097677
```

O coeficiente estimado de `mailsyear` é 0.062. Portanto, uma correspondência adicional por ano altera a probabilidade prevista de resposta em aproximadamente 6.2 pontos percentuais, mantidas as demais variáveis fixas.

Essa estimativa, porém, não deve ser interpretada como causal. A conclusão objetiva aqui é: `mailsyear` pode estar correlacionada com características não observadas do doador, de modo que seu coeficiente tem interpretação associativa, e não necessariamente causal.

Lista 10

Questao 5)

Agora resolvemos a Quest~ao computacional da Lista 10 com a base FERTIL2.

```
library(wooldridge)
library(stargazer)
library(lmtest)
library(sandwich)

data("fertil2")
head(fertil2)
```

```
##      mnthborn yearborn age electric radio tv bicycle educ ceb agefbrth children
## 1          5        64 24          1      1 1          1 12  0         NA         0
## 2          1        56 32          1      1 1          1 13  3         25         3
## 3          7        58 30          1      0 0          0  5  1         27         1
## 4         11        45 42          1      0 1          0  4  3         17         2
## 5          5        45 43          1      1 1          1 11  2         24         2
## 6          8        52 36          1      0 0          0  7  1         26         1
##      knowmeth usemeth monthfm yearfm agefm idlnchld heduc agesq urban urb_educ
## 1          1          0        NA      NA      NA          2    NA   576         1        12
## 2          1          1        11      80      24          3    12  1024         1        13
## 3          1          0          6      83      24          5     7   900         1         5
## 4          1          0          1      61      15          3    11  1764         1         4
## 5          1          1          3      66      20          2    14  1849         1        11
## 6          1          1        11      76      24          4     9  1296         1         7
##      spirit protest catholic frsthalf educ0 evermarr
## 1          0          0          0          1          0          0
## 2          0          0          0          1          0          1
## 3          1          0          0          0          0          1
## 4          0          0          0          0          0          1
## 5          0          1          0          1          0          1
## 6          0          0          0          0          0          1
```

- (i)

Primeiro estimamos o modelo pedido e registramos erros padr~ao usuais e robustos.

```
mod10_i <- lm(children ~ age + I(age^2) + educ + electric + urban, data = fertil2)
summary(mod10_i)
```

```
##
## Call:
## lm(formula = children ~ age + I(age^2) + educ + electric + urban,
##     data = fertil2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.9012 -0.7136 -0.0039  0.7119  7.4318
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -4.2225162   0.2401888 -17.580 < 0.0000000000000002 ***
## age          0.3409255   0.0165082  20.652 < 0.0000000000000002 ***
## I(age^2)     -0.0027412   0.0002718 -10.086 < 0.0000000000000002 ***
```

```
## educ      -0.0752323  0.0062966 -11.948 < 0.0000000000000002 ***
## electric  -0.3100404  0.0690045  -4.493      0.0000072 ***
## urban     -0.2000339  0.0465062  -4.301      0.0000174 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.452 on 4352 degrees of freedom
## (3 observations deleted due to missingness)
## Multiple R-squared:  0.5734, Adjusted R-squared:  0.5729
## F-statistic: 1170 on 5 and 4352 DF, p-value: < 0.00000000000000022
```

```
stargazer(mod10_i, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      children
## -----
## age                  0.3409***
##                      (0.0165)
##
## I(age2)              -0.0027***
##                      (0.0003)
##
## educ                 -0.0752***
##                      (0.0063)
##
## electric             -0.3100***
##                      (0.0690)
##
## urban               -0.2000***
##                      (0.0465)
##
## Constant             -4.2225***
##                      (0.2402)
##
## -----
## Observations          4,358
## R2                    0.5734
## Adjusted R2           0.5729
## Residual Std. Error   1.4521 (df = 4352)
## F Statistic           1,169.8690*** (df = 5; 4352)
## =====
## Note:                 *p<0.1; **p<0.05; ***p<0.01
```

```
coeftest(mod10_i, vcov. = vcovHC(mod10_i, type = "HC1"))
```

```
##
## t test of coefficients:
##
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -4.22251623  0.24385099 -17.3160 < 0.00000000000000022 ***
## age          0.34092552  0.01917466  17.7800 < 0.00000000000000022 ***
## I(age^2)     -0.00274121  0.00035051  -7.8206  0.000000000000006549 ***
```

```
## educ      -0.07523232  0.00630771 -11.9270 < 0.00000000000000022 ***
## electric  -0.31004041  0.06394815  -4.8483  0.000001288602433705 ***
## urban     -0.20003386  0.04547093  -4.3992  0.000011126949912489 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O ponto principal aqui é comparar os erros padrão usuais com os robustos. Em geral, eles não precisam ser sempre maiores: a heteroscedasticidade pode aumentar alguns e reduzir outros.

- (ii)

Agora adicionamos três dummies de religião.

```
mod10_ii <- lm(children ~ age + I(age^2) + educ + electric + urban +
               spirit + protest + catholic,
               data = fertil2)
```

```
summary(mod10_ii)
```

```
##
## Call:
## lm(formula = children ~ age + I(age^2) + educ + electric + urban +
##      spirit + protest + catholic, data = fertil2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.9514 -0.7041 -0.0101  0.7213  7.4435
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -4.3147175  0.2433391 -17.731 < 0.00000000000000022 ***
## age          0.3418668  0.0165186  20.696 < 0.00000000000000002 ***
## I(age^2)     -0.0027596  0.0002722 -10.139 < 0.00000000000000002 ***
## educ         -0.0762130  0.0064608 -11.796 < 0.00000000000000002 ***
## electric     -0.3057189  0.0690241  -4.429    0.00000969 ***
## urban        -0.2034131  0.0465864  -4.366    0.00001293 ***
## spirit         0.1404603  0.0558052   2.517     0.0119 *
## protest       0.0753961  0.0652158   1.156     0.2477
## catholic      0.1173539  0.0834249   1.407     0.1596
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.451 on 4349 degrees of freedom
## (3 observations deleted due to missingness)
## Multiple R-squared:  0.574, Adjusted R-squared:  0.5733
## F-statistic: 732.6 on 8 and 4349 DF, p-value: < 0.00000000000000022
```

```
stargazer(mod10_ii, type = "text", digits = 4)
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      children
##                      -----
## age                  0.3419***
##                      (0.0165)
```



```

##
## I(age2)                -0.0028***
##                        (0.0003)
##
## educ                   -0.0762***
##                        (0.0065)
##
## electric               -0.3057***
##                        (0.0690)
##
## urban                  -0.2034***
##                        (0.0466)
##
## spirit                  0.1405**
##                        (0.0558)
##
## protest                 0.0754
##                        (0.0652)
##
## catholic                0.1174
##                        (0.0834)
##
## Constant               -4.3147***
##                        (0.2433)
##
## -----
## Observations            4,358
## R2                      0.5740
## Adjusted R2             0.5733
## Residual Std. Error    1.4515 (df = 4349)
## F Statistic             732.5945*** (df = 8; 4349)
## =====
## Note:                   *p<0.1; **p<0.05; ***p<0.01
anova(mod10_i, mod10_ii)

## Analysis of Variance Table
##
## Model 1: children ~ age + I(age^2) + educ + electric + urban
## Model 2: children ~ age + I(age^2) + educ + electric + urban + spirit +
##          protest + catholic
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1    4352 9176.4
## 2    4349 9162.5  3     13.88 2.1961 0.08641 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

waldtest(mod10_i, mod10_ii, vcov = vcovHC(mod10_ii, type = "HC1"), test = "F")

## Wald test
##
## Model 1: children ~ age + I(age^2) + educ + electric + urban
## Model 2: children ~ age + I(age^2) + educ + electric + urban + spirit +
##          protest + catholic
##   Res.Df Df    F Pr(>F)

```

```
## 1    4352
## 2    4349   3 2.1559 0.0911 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Com isso, obtemos:

- o teste F usual da significância conjunta das tres dummies;
- e o teste robusto a heteroscedasticidade para as mesmas restrições.

Os p-valores desses dois testes são:

- teste F usual: 0.08641;
- teste F robusto: 0.0911.

O p-valor usual é 0.08641, que é não menor que 0,05. O p-valor robusto é 0.0911, que é não menor que 0,05. Portanto, não rejeitamos a hipótese nula de insignificância conjunta das dummies de religião pelo teste usual; e não rejeitamos essa hipótese pelo teste robusto.

- (iii)

Agora avaliamos a heteroscedasticidade a partir da regressão auxiliar sobre os resíduos ao quadrado.

```
uhat10 <- resid(mod10_ii)
yhat10 <- fitted(mod10_ii)

mod10_aux <- lm(I(uhat10^2) ~ yhat10 + I(yhat10^2))
summary(mod10_aux)

##
## Call:
## lm(formula = I(uhat10^2) ~ yhat10 + I(yhat10^2))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8.873 -1.290 -0.302  0.357 47.684
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)   0.3126     0.1114   2.807    0.00503 **
## yhat10        -0.1489     0.1018  -1.462    0.14381
## I(yhat10^2)    0.2668     0.0196  13.607 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.632 on 4355 degrees of freedom
## Multiple R-squared:  0.2501, Adjusted R-squared:  0.2497
## F-statistic: 726.1 on 2 and 4355 DF,  p-value: < 0.00000000000000022
anova(lm(I(uhat10^2) ~ 1), mod10_aux)

## Analysis of Variance Table
##
## Model 1: I(uhat10^2) ~ 1
## Model 2: I(uhat10^2) ~ yhat10 + I(yhat10^2)
##   Res.Df  RSS Df Sum of Sq    F        Pr(>F)
## 1     4357 76589
## 2     4355 57436   2     19153 726.11 < 0.00000000000000022 ***
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O p-valor desse teste auxiliar é 0, que é menor que 0,05. Portanto, rejeitamos homocedasticidade e concluímos que há evidência de heterocedasticidade.

- (iv)

No item (iii), rejeitamos homocedasticidade. Comparando os resultados usuais e robustos dos itens (i) e (ii), a conclusão final é: a heterocedasticidade não é importante na prática, porque as conclusões substantivas não mudam.

Lista 11

Questão 5)

Agora resolvemos a Questão computacional da Lista 11 com a base ECONMATH.

```
library(wooldridge)
library(stargazer)
library(lmtest)
library(sandwich)

data("econmath")
head(econmath)
```

```
##   age work study econhs colgpa hsgpa acteng actmth act mathscr male calculus
## 1  23   15  10.0     0 3.4909 3.355   24   26  27    10    1         1
## 2  23    0  22.5     1 2.1000 3.219   23   20  24     9    1         0
## 3  21   25  12.0     0 3.0851 3.306   21   24  21     8    1         1
## 4  22   30  40.0     0 2.6805 3.977   31   28  31    10    0         1
## 5  22   25  15.0     1 3.7454 3.890   28   31  32     8    1         1
## 6  22    0  30.0     0 3.0555 3.500   25   30  28    10    1         1
##   attexc attgood fathcoll mothcoll score
## 1      0      0         1         1 84.43
## 2      0      0         0         1 57.38
## 3      1      0         0         1 66.39
## 4      0      1         1         1 81.15
## 5      0      1         0         1 95.90
## 6      1      0         0         1 83.61
```

- (i)

Primeiro, identificamos quantos estudantes não possuem nota de act.

```
econmath$actmiss <- as.integer(is.na(econmath$act))
```

```
n_missing_act <- sum(econmath$actmiss)
frac_missing_act <- mean(econmath$actmiss)
```

```
n_missing_act
```

```
## [1] 42
```

```
frac_missing_act
```

```
## [1] 0.04906542
```

Logo, há 42 estudantes com act ausente, o que corresponde a aproximadamente 4.91% da amostra.

- (ii)

Agora criamos `act0`, que coincide com `act` quando ela é observada e vale zero quando `act` está ausente.

```
econmath$act0 <- ifelse(is.na(econmath$act), 0, econmath$act)
```

```
mean_act0 <- mean(econmath$act0)
```

```
mean_act <- mean(econmath$act, na.rm = TRUE)
```

```
mean_act0
```

```
## [1] 21.98715
```

```
mean_act
```

```
## [1] 23.12162
```

Como `act0` coloca zero nos casos ausentes, sua média tende a ser menor do que a média de `act` calculada apenas entre observações válidas.

- (iii)

Agora estimamos a regressão simples de `score` sobre `act` usando apenas casos completos e calculamos o erro padrão robusto.

```
mod11_iii <- lm(score ~ act, data = econmath, subset = !is.na(act))
```

```
summary(mod11_iii)
```

```
##
```

```
## Call:
```

```
## lm(formula = score ~ act, data = econmath, subset = !is.na(act))
```

```
##
```

```
## Residuals:
```

```
##      Min       1Q   Median       3Q      Max
```

```
## -45.918  -8.215   1.076   9.458  31.410
```

```
##
```

```
## Coefficients:
```

```
##              Estimate Std. Error t value      Pr(>|t|)
```

```
## (Intercept)  36.8160     2.9995   12.27 <0.0000000000000002 ***
```

```
## act          1.5480     0.1284   12.06 <0.0000000000000002 ***
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
```

```
## Residual standard error: 12.26 on 812 degrees of freedom
```

```
## Multiple R-squared:  0.1518, Adjusted R-squared:  0.1508
```

```
## F-statistic: 145.4 on 1 and 812 DF, p-value: < 0.00000000000000022
```

```
stargazer(mod11_iii, type = "text", digits = 4)
```

```
##
```

```
## =====
```

```
##              Dependent variable:
```

```
## -----
```

```
##              score
```

```
## -----
```

```
## act              1.5480***
```

```
##              (0.1284)
```

```
##
```

```
## Constant        36.8160***
```

```
##              (2.9995)
```

```
##
```

```
## -----
## Observations      814
## R2                0.1518
## Adjusted R2       0.1508
## Residual Std. Error 12.2603 (df = 812)
## F Statistic       145.3760*** (df = 1; 812)
## =====
## Note:              *p<0.1; **p<0.05; ***p<0.01
coeftest(mod11_iii, vcov. = vcovHC(mod11_iii, type = "HC1"))

##
## t test of coefficients:
##
##           Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 36.81604    3.40403  10.815 < 0.00000000000000022 ***
## act         1.54802     0.14284   10.838 < 0.00000000000000022 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O coeficiente de act nesta regressão mede quanto a nota final do curso aumenta, em média, para um ponto adicional no ACT, usando somente os alunos para os quais essa nota foi observada.

- (iv)

Agora usamos todos os casos, substituindo act por act0.

```
mod11_iv <- lm(score ~ act0, data = econmath)
summary(mod11_iv)

##
## Call:
## lm(formula = score ~ act0, data = econmath)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -50.889  -8.269   1.350   9.510  35.367
##
## Coefficients:
##           Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 62.29261    1.71140   36.40 < 0.0000000000000002 ***
## act0         0.46878    0.07512    6.24  0.000000000686 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 13.11 on 854 degrees of freedom
## Multiple R-squared:  0.04361,    Adjusted R-squared:  0.04249
## F-statistic: 38.94 on 1 and 854 DF,  p-value: 0.0000000006863
stargazer(mod11_iv, type = "text", digits = 4)

##
## =====
##                Dependent variable:
##                -----
##                score
##                -----
## act0                0.4688***
```

```
##                                (0.0751)
##
## Constant                      62.2926***
##                                (1.7114)
##
## -----
## Observations                  856
## R2                           0.0436
## Adjusted R2                   0.0425
## Residual Std. Error    13.1129 (df = 854)
## F Statistic             38.9433*** (df = 1; 854)
## =====
## Note:                       *p<0.1; **p<0.05; ***p<0.01
coeftest(mod11_iv, vcov. = vcovHC(mod11_iv, type = "HC1"))

##
## t test of coefficients:
##
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)  62.292606   2.285800  27.2520 < 0.00000000000000022 ***
## act0         0.468783   0.096666   4.8495   0.00000147 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

O coeficiente de act0 no item (iv) deve ser comparado com o coeficiente de act no item (iii). Como zero n~ao e uma nota plaus'ivel de ACT, tratar ausencias como zero distorce a inclinaç~ao. Portanto, a estimativa do item (iv) n~ao deve ser preferida a do item (iii).

- (v)

Agora incluimos tambem a dummy actmiss.

```
mod11_v <- lm(score ~ act0 + actmiss, data = econmath)
summary(mod11_v)

##
## Call:
## lm(formula = score ~ act0 + actmiss, data = econmath)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -52.897  -8.237   1.074   9.560  31.410
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)  36.8160     3.0398  12.111 <0.0000000000000002 ***
## act0         1.5480     0.1301  11.897 <0.0000000000000002 ***
## actmiss      35.6109     3.5939   9.909 <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 12.42 on 853 degrees of freedom
## Multiple R-squared:  0.1423, Adjusted R-squared:  0.1403
## F-statistic: 70.78 on 2 and 853 DF, p-value: < 0.00000000000000022
```

```

stargazer(mod11_v, type = "text", digits = 4)

##
## =====
##                               Dependent variable:
##                               -----
##                               score
## -----
## act0                        1.5480***
##                               (0.1301)
##
## actmiss                     35.6109***
##                               (3.5939)
##
## Constant                   36.8160***
##                               (3.0398)
##
## -----
## Observations                856
## R2                          0.1423
## Adjusted R2                 0.1403
## Residual Std. Error       12.4250 (df = 853)
## F Statistic                70.7789*** (df = 2; 853)
## =====
## Note:                       *p<0.1; **p<0.05; ***p<0.01
coeftest(mod11_v, vcov. = vcovHC(mod11_v, type = "HC1"))

```

```

##
## t test of coefficients:
##
##           Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 36.81604    3.40582 10.8097 < 0.00000000000000022 ***
## act0         1.54802    0.14291 10.8318 < 0.00000000000000022 ***
## actmiss      35.61086    4.13250  8.6173 < 0.00000000000000022 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Aqui, `actmiss` permite um deslocamento de intercepto para o grupo com ACT ausente. A inclinação estimada de `act0` no item (v) é 1.548, contra 1.548 no item (iii) e 0.4688 no item (iv). Portanto, a inclusão de `actmiss` melhora a especificação, pois aproxima a inclinação daquela obtida com casos completos.

- (vi)

O coeficiente de `act0` em (v) fica a 0 da estimativa de casos completos, enquanto em (iv) essa distância é 1.0792. Portanto, o uso de todos os casos com a dummy `actmiss` melhora a estimação de `beta_1`.

- (vii)

Por fim, adicionamos `colgpa` as especificações dos itens (iii) e (v).

```

mod11_vii_cc <- lm(score ~ act + colgpa, data = econmath, subset = !is.na(act))
mod11_vii_full <- lm(score ~ act0 + actmiss + colgpa, data = econmath)

stargazer(mod11_vii_cc, mod11_vii_full, type = "text", digits = 4,
           column.labels = c("Casos completos", "Todos os casos"))

```

```
##
```

```
## =====
##                               Dependent variable:
##                               -----
##                               score
##                               Casos completos      Todos os casos
##                               (1)                  (2)
## -----
## act                          0.8791***
##                               (0.1164)
##
## act0                          0.8743***
##                               (0.1180)
##
## actmiss                       19.0859***
##                               (3.2229)
##
## colgpa                       12.5096***
##                               (0.7230)
##                               12.5993***
##                               (0.7182)
##
## Constant                     17.1189***
##                               (2.8063)
##                               16.9776***
##                               (2.8417)
## -----
## Observations                  814
## R2                           0.3805
## Adjusted R2                   0.3790
## Residual Std. Error    10.4845 (df = 811)
## F Statistic            249.0788*** (df = 2; 811)
##                               10.6558 (df = 852)
##                               166.7387*** (df = 3; 852)
## =====
## Note:                        *p<0.1; **p<0.05; ***p<0.01
```

```
coeftest(mod11_vii_cc, vcov. = vcovHC(mod11_vii_cc, type = "HC1"))
```

```
##
## t test of coefficients:
##
##           Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 17.11886   3.24492  5.2756    0.000000169927521 ***
## act          0.87907   0.12609  6.9719    0.0000000000006482 ***
## colgpa       12.50957   0.74679 16.7511 < 0.00000000000000022 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
coeftest(mod11_vii_full, vcov. = vcovHC(mod11_vii_full, type = "HC1"))
```

```
##
## t test of coefficients:
##
##           Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 16.97759   3.24573  5.2308    0.000000212615750 ***
## act0         0.87427   0.12634  6.9200    0.0000000000008879 ***
## actmiss      19.08589   3.71352  5.1396    0.000000341647207 ***
## colgpa       12.59929   0.75448 16.6994 < 0.00000000000000022 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


No modelo com `colgpa`, a distancia entre a inclinaç~ao de casos completos e a da amostra total com `actmiss` e 0.0048. Sem `colgpa`, essa distancia era 0. Portanto, apos incluir `colgpa`, a resposta ao item (vi) nao fica mais favoravel ao uso do modelo com `actmiss`.