

Lista 12 Gabarito - Econometria I - 2026

Prof: André Luiz Pereira Mancha

Monitor: Tuffy Licciardi Issa

- 1.* (17.2, (?)) Defina *grad* como uma variável *dummy* que indica se um estudante-atleta de uma grande universidade se formará dentro de cinco anos. Sejam *hsGPA* a nota média no ensino médio e *SAT* a pontuação total no exame SAT. Defina *study* como o número médio de horas por semana passadas em uma sala de estudo organizada. Suponha que, usando os dados de 420 estudantes-atletas, obtenha-se o seguinte modelo logit:

$$P(\text{grad} = 1 \mid \text{hsGPA}, \text{SAT}, \text{study}) = \Lambda(-1,17 + 0,24 \text{hsGPA} + 0,00058 \text{SAT} + 0,073 \text{study}),$$

em que $\Lambda(z) = \exp(z)/[1 + \exp(z)]$ é a função logit.

- (i) Mantendo fixos *hsGPA* em 3,0 e *SAT* em 1.200, calcule a diferença estimada na probabilidade de formatura de alguém que tenha passado dez horas por semana em uma sala de estudo e de alguém que tenha passado cinco horas por semana.
- (ii) Explique.

R:

- (i) Para *study* = 10,

$$z_{10} = -1,17 + 0,24(3,0) + 0,00058(1200) + 0,073(10) = 0,976.$$

Logo,

$$\Lambda(z_{10}) = \frac{e^{0,976}}{1 + e^{0,976}} \approx 0,726.$$

Para *study* = 5,

$$z_5 = -1,17 + 0,24(3,0) + 0,00058(1200) + 0,073(5) = 0,611,$$

de modo que

$$\Lambda(z_5) = \frac{e^{0,611}}{1 + e^{0,611}} \approx 0,648.$$

Portanto, a diferença estimada é

$$0,726 - 0,648 = 0,078.$$

Assim, passar de cinco para dez horas semanais na sala de estudo eleva a probabilidade estimada de formatura em aproximadamente 7,8 pontos percentuais.

- (ii) O efeito não é exatamente igual a $5 \times 0,073$, porque 0,073 é o efeito sobre o índice latente do logit, e não diretamente sobre a probabilidade. A relação entre o índice e a probabilidade é não linear. Por isso, a variação na probabilidade deve ser calculada comparando $\Lambda(z_{10})$ e $\Lambda(z_5)$.

2. (17.5, (?)) Defina *patents* como o número de patentes requeridas por uma firma durante determinado ano. Assuma que o valor esperado condicional de *patents*, dados *sales* e *PD*, é

$$E(\textit{patents} \mid \textit{sales}, PD) = \exp\{\beta_0 + \beta_1 \log(\textit{sales}) + \beta_2 PD + \beta_3 PD^2\},$$

em que *sales* representa as vendas anuais da firma e *PD* é o total de gastos com pesquisa e desenvolvimento nos últimos três anos.

- (i) Como você estimaria os β_j ? Escreva sua resposta detalhando a natureza de *patents*.
- (ii) Como você interpreta β_1 ?
- (iii) Encontre o efeito parcial de *PD* sobre $E(\textit{patents} \mid \textit{sales}, PD)$.

R:

- (i) Como *patents* é uma variável de contagem não negativa, o procedimento natural é usar um modelo de regressão de Poisson por máxima verossimilhança, especificando

$$E(\textit{patents} \mid \textit{sales}, PD) = \exp\{\beta_0 + \beta_1 \log(\textit{sales}) + \beta_2 PD + \beta_3 PD^2\}.$$

Mesmo que a distribuição condicional não seja exatamente Poisson, o estimador de quase-máxima verossimilhança de Poisson continua apropriado desde que a média condicional esteja corretamente especificada.

- (ii) Como $\log(\textit{sales})$ entra linearmente no índice, β_1 é uma elasticidade semielástica da média condicional: um aumento de 1% em *sales* altera $E(\textit{patents} \mid \textit{sales}, PD)$ em aproximadamente $\beta_1/100$ em termos proporcionais. De forma equivalente, um aumento de 1% nas vendas altera o número esperado de patentes em aproximadamente $100\beta_1/100 = \beta_1\%$.
- (iii) Seja

$$\mu(x) = E(\textit{patents} \mid \textit{sales}, PD) = \exp\{\beta_0 + \beta_1 \log(\textit{sales}) + \beta_2 PD + \beta_3 PD^2\}.$$

Então,

$$\frac{\partial \mu(x)}{\partial PD} = \mu(x) (\beta_2 + 2\beta_3 PD).$$

Portanto, o efeito parcial de PD é

$$\frac{\partial E(patents \mid sales, PD)}{\partial PD} = E(patents \mid sales, PD) (\beta_2 + 2\beta_3 PD).$$

- 3.* (17.6, (?)) Considere uma função de poupança familiar para a população de todas as famílias dos Estados Unidos:

$$sav = \beta_0 + \beta_1 inc + \beta_2 hsize + \beta_3 educ + \beta_4 age + u,$$

em que $hsize$ é o tamanho da família, $educ$ são anos de escolaridade do chefe da família e age é a idade do chefe da família. Assuma que

$$E(u \mid inc, hsize, educ, age) = 0.$$

- (i) Suponha que a amostra inclua apenas famílias cujo chefe tenha mais de 25 anos. Se usarmos o MQO nessa amostra, obteremos estimadores não viesados dos β_j ? Explique.

R: Sim, desde que a seleção da amostra dependa apenas das variáveis explicativas observadas, isto é, da restrição $age > 25$, e que a condição de média condicional nula continue válida na amostra selecionada:

$$E(u \mid inc, hsize, educ, age, age > 25) = 0.$$

Como a seleção é baseada em uma variável explicativa já presente no modelo, não há problema de viés de seleção por si só. O que muda é que a inferência passa a valer para a subpopulação com chefes de família acima de 25 anos. Portanto, o MQO continua produzindo estimadores não viesados e consistentes dos coeficientes, sob essa condição adicional.

- 4.* (17.8, (?)) Considere o problema de avaliação de programas, em que $y(0)$ e $y(1)$ são os resultados potenciais sem e com tratamento, respectivamente. Seja w o indicador binário de tratamento. Sob as funções médias condicionais, defina

$$m_0(x) = E[y(0) \mid x] \quad \text{e} \quad m_1(x) = E[y(1) \mid x].$$

Lembre-se de que o efeito médio do tratamento é

$$\tau_{ate} = \mu_1 - \mu_0 = E[y(1)] - E[y(0)]$$

e que também pode ser escrito como

$$\tau_{ate} = E[m_1(x)] - E[m_0(x)].$$

(i) Explique por que

$$\tau_{ate} = n^{-1} \sum_{i=1}^n [m_1(x_i) - m_0(x_i)]$$

se $x_1, \dots, x_n$ forem tratados como uma amostra aleatória.

(ii) Se você conhecesse as funções $m_0(x)$ e $m_1(x)$ e dispusesse de uma amostra aleatória $x_1, \dots, x_n$, explique por que

$$\hat{\tau}_{ate} = n^{-1} \sum_{i=1}^n [m_1(x_i) - m_0(x_i)]$$

seria um estimador não viesado de τ_{ate} .

(iii) Agora considere os modelos $m_0(x, \theta_0)$ e $m_1(x, \theta_1)$, em que θ_0 e θ_1 são parâmetros e estimadores $\hat{\theta}_0$ e $\hat{\theta}_1$. Defina

$$\hat{\tau}_{ate} = n^{-1} \sum_{i=1}^n [m_1(x_i, \hat{\theta}_1) - m_0(x_i, \hat{\theta}_0)].$$

Como você estimaria τ_{ate} ?

(iv) Defina a resposta observada como de costume:

$$y = (1 - w)y(0) + wy(1).$$

Mostre que, se w é independente de $[y(0), y(1)]$ condicional em x , então

$$E(y \mid w, x) = (1 - w)m_0(x) + wm_1(x).$$

Portanto,

$$E(y \mid w = 0, x) = m_0(x) \quad \text{e} \quad E(y \mid w = 1, x) = m_1(x).$$

(v) Se $y(0)$ e $y(1)$ seguirem modelos logit ou probit com probabilidades de resposta:

$$G(\alpha_0 + x'\beta_0) \quad \text{e} \quad G(\alpha_1 + x'\beta_1),$$

respectivamente, como você estimaria todos os parâmetros? Como você estimaria τ_{ate} ?

R:

(i) Como

$$\tau_{ate} = E[m_1(x) - m_0(x)],$$

e $x_1, \dots, x_n$ são uma amostra aleatória, a média amostral de $m_1(x_i) - m_0(x_i)$ é a contraparte natural da esperança populacional. Assim,

$$\tau_{ate} \approx n^{-1} \sum_{i=1}^n [m_1(x_i) - m_0(x_i)].$$

Em amostras grandes, pela Lei dos Grandes Números, essa média converge para $E[m_1(x) - m_0(x)]$.

(ii) Como $x_1, \dots, x_n$ formam uma amostra aleatória,

$$E \left[n^{-1} \sum_{i=1}^n (m_1(x_i) - m_0(x_i)) \right] = E[m_1(x) - m_0(x)] = \tau_{ate}.$$

Portanto, o estimador proposto é não viesado para τ_{ate} .

(iii) O procedimento é estimar θ_0 e θ_1 pelos métodos adequados ao modelo escolhido e, em seguida, substituir esses estimadores na expressão

$$\hat{\tau}_{ate} = n^{-1} \sum_{i=1}^n [\hat{m}_1(x_i) - \hat{m}_0(x_i)].$$

Ou seja,

$$\hat{m}_0(x_i) = m_0(x_i, \hat{\theta}_0), \quad \hat{m}_1(x_i) = m_1(x_i, \hat{\theta}_1),$$

e calcula-se a média amostral das diferenças previstas.

(iv) Como

$$y = (1 - w)y(0) + wy(1),$$

temos

$$E(y \mid w, x) = (1 - w)E[y(0) \mid w, x] + wE[y(1) \mid w, x].$$

Sob independência condicional de w em relação a $[y(0), y(1)]$, segue que

$$E[y(0) \mid w, x] = E[y(0) \mid x] = m_0(x)$$

e

$$E[y(1) \mid w, x] = E[y(1) \mid x] = m_1(x).$$

Logo,

$$E(y \mid w, x) = (1 - w)m_0(x) + wm_1(x).$$

Portanto,

$$E(y \mid w = 0, x) = m_0(x) \quad \text{e} \quad E(y \mid w = 1, x) = m_1(x).$$

- (v) Esses resultados mostram que podemos estimar separadamente, nos grupos $w = 0$ e $w = 1$, dois modelos logit ou probit:

$$\hat{m}_0(x) = G(\hat{\alpha}_0 + x'\hat{\beta}_0), \quad \hat{m}_1(x) = G(\hat{\alpha}_1 + x'\hat{\beta}_1).$$

Por fim, calcula-se

$$\hat{\tau}_{ate} = n^{-1} \sum_{i=1}^n [\hat{m}_1(x_i) - \hat{m}_0(x_i)].$$

- 5.* (17.C1, (?)) Use os dados de PNTSPRD neste exercício. A variável *favwin* é binária e vale um se o time favorito vence a partida. Um modelo de probabilidade linear para estimar a probabilidade de o time favorito vencer é:

$$P(\text{favwin} = 1 \mid \text{spread}) = \beta_0 + \beta_1 \text{spread}.$$

- (i) Explique por que, caso a aposta incorpore todas as informações relevantes, esperaríamos $\beta_0 = 0,5$.
- (ii) Estime o modelo do item (i) por MQO. Teste $H_0 : \beta_0 = 0,5$ em relação a uma alternativa bilateral. Use erros padrão usuais e robustos em relação à heteroscedasticidade.
- (iii) Qual é a probabilidade estimada de o time favorito vencer quando *spread* = 10 e ela é estatisticamente significativa?
- (iv) Agora, estime um modelo Probit para $P(\text{favwin} = 1 \mid \text{spread})$. Interprete e teste a hipótese nula de que o intercepto é zero. [Dica: lembre-se de que $\Phi(0) = 0,5$.]
- (v) Use o modelo Probit para estimar a probabilidade de que o time favorito vença, caso *spread* = 10. Compare esse resultado com a estimativa MQO do item (iii).
- (vi) Adicione as variáveis *favhome*, *fav25* e *und25* ao modelo Probit e teste a significância conjunta dessas variáveis usando o teste de razão de verossimilhança (quantos gl estão na distribuição qui-quadrado?). Interprete esse resultado, focando na possibilidade de que o *spread* incorpore todas as informações observáveis antes de um jogo.

R:

- (i) Se *spread* = 0, as casas de aposta consideram os times equilibrados. Nesse caso, a probabilidade prevista de vitória do favorito deve ser 0,5. Como, no modelo linear,

$$P(\text{favwin} = 1 \mid \text{spread} = 0) = \beta_0,$$

segue que, sob incorporação completa das informações relevantes, esperaríamos $\beta_0 = 0,5$.

- (ii) A parte empírica deve ser feita no software com MQO e, para o teste bilateral, usa-se

$$t = \frac{\hat{\beta}_0 - 0,5}{se(\hat{\beta}_0)},$$

tanto com erro padrão usual quanto com erro padrão robusto. A conclusão depende dos resultados numéricos da amostra.

- (iii) A probabilidade estimada pelo modelo linear é

$$\hat{P}(favwin = 1 \mid spread = 10) = \hat{\beta}_0 + 10\hat{\beta}_1.$$

Para verificar a significância, testa-se $H_0 : \beta_0 + 10\beta_1 = 0$ ou, mais relevantemente, examina-se se a probabilidade prevista é estimada com precisão, usando o erro padrão da combinação linear. Numericamente, isso deve ser calculado após a estimação.

- (iv) No probit,

$$P(favwin = 1 \mid spread) = \Phi(\gamma_0 + \gamma_1 spread).$$

Se $\gamma_0 = 0$, então

$$P(favwin = 1 \mid spread = 0) = \Phi(0) = 0,5.$$

Portanto, a hipótese $H_0 : \gamma_0 = 0$ verifica se, quando não há favoritismo pelo *spread*, a probabilidade prevista de vitória é 50%. O teste é um teste t ou z usual sobre o intercepto estimado.

- (v) A probabilidade prevista no probit para $spread = 10$ é

$$\hat{P}(favwin = 1 \mid spread = 10) = \Phi(\hat{\gamma}_0 + 10\hat{\gamma}_1).$$

Essa previsão deve ser comparada com a do MQO,

$$\hat{\beta}_0 + 10\hat{\beta}_1.$$

Em geral, os valores são próximos no centro da distribuição, mas o probit garante previsões entre zero e um.

- (vi) O teste de razão de verossimilhança compara o modelo restrito, com apenas *spread*, ao modelo irrestrito, com *spread*, *favhome*, *fav25* e *und25*. A estatística é

$$LR = 2(\ell_{irrestrito} - \ell_{restrito}),$$

que, sob H_0 , tem distribuição qui-quadrado com 3 graus de liberdade. Se H_0 não for rejeitada, isso sugere que, dado o *spread*, essas variáveis adicionais não trazem informação relevante, reforçando a ideia de que o *spread* já resume bem as informações observáveis antes do jogo. Se H_0 for rejeitada, então o *spread* não incorpora toda a informação disponível.

Referências