Lista 7 Gabarito - Econometria I - 2026

Prof: Andre Luiz Pereira Mancha
Monitor: Tuffy Licciardi Issa

---

1. (6.7, (Wooldridge, 2023)). As tres seguintes equacoes foram estimadas utilizando-se as 1.534 observacoes contidas no arquivo `401K`.

$$\widehat{prate} = 80{,}29 + 5{,}44\,mrate + 0{,}269\,age - 0{,}00013\,totemp$$
$$(0{,}78) \qquad (0{,}52) \qquad (0{,}045) \qquad (0{,}00004)$$
$$R^2 = 0{,}100, \bar{R}^2 = 0,098$$

$$\widehat{prate} = 97{,}32 + 5{,}02\,mrate + 0{,}314\,age - 2{,}66\,\log(totemp)$$
$$(1{,}95) \qquad (0{,}51) \qquad (0{,}044) \qquad (0{,}28)$$
$$R^2 = 0{,}144, \bar{R}^2 = 0,142$$

$$\widehat{prate} = 80{,}62 + 5{,}34\,mrate + 0{,}290\,age - 0{,}00043\,totemp$$
$$(0{,}78) \qquad (0{,}52) \qquad (0{,}045) \qquad (0{,}00009)$$
$$+\,0{,}0000000039\,totemp^2$$
$$(0{,}00000000010)$$
$$R^2 = 0{,}108, \bar{R}^2 = 0,106$$

Qual desses tres modelos voce prefere? Por que?

R: A **segunda especificacao** é preferível. Ela tem o maior R^2 ajustado (0,142), e o uso de $\log(totemp)$ parece mais razoável economicamente, pois permite um efeito marginal decrescente do tamanho da firma sobre a taxa de participação. Assim, pela combinação de **melhor ajuste**, **parcimônia** e **interpretação econômica mais plausível**, a segunda equação e a melhor escolha.

2.* (6.10, (Wooldridge, 2023)). As duas equações seguintes foram estimadas usando dados do arquivo `MEAPSINGLE`. A principal variável explicativa e `lexppp`, o log dos gastos por estudante em nível escolar.

$$\widehat{math4} = 24{,}49 + 9{,}01\,lexppp - 0{,}422\,free - 0{,}752\,lmedinc - 0{,}274\,pctsgle$$

$$(59{,}24) \qquad (4{,}04) \qquad (0{,}071) \qquad (5{,}358) \qquad (0{,}161)$$
$$n = 229, \quad R^2 = 0{,}472, \quad \bar{R}^2 = 0{,}462.$$

$$\widehat{math4} = 149{,}38 + 1{,}93\, lexppp - 0{,}060\, free - 10{,}78\, lmedinc - 0{,}397\, pctsgle + 0{,}667\, read4$$
$$(41{,}70) \qquad (2{,}82) \qquad (0{,}054) \qquad (3{,}76) \qquad (0{,}111) \qquad (0{,}042)$$
$$n = 229, \quad R^2 = 0{,}749, \quad \bar{R}^2 = 0{,}743.$$

(i) Se você for um gestor de politicas publicas tentando estimar o efeito causal dos gastos por estudante sobre o desempenho na prova de matemática, explique por que a primeira equação e mais relevante do que a segunda. Qual e o efeito estimado de um aumento de 10% nos gastos por estudante?

(ii) A adição de `read4` a regressão tem efeitos estranhos sobre os coeficientes e significância alem de β_{lexppp}?

(iii) De que forma você explicaria a alguém com apenas um conhecimento básico de regressões por que, neste caso, você preferiria a equação com o menor R-quadrado ajustado?

R:

(i) A primeira equação e mais relevante para inferência causal porque `read4` e uma variável de desempenho escolar muito próxima de `math4`. Ao inclui-la, parte do efeito dos gastos sobre matemática pode ser "absorvida" por uma variável que também reflete desempenho educacional. Em um modelo nivel-log, um aumento de 10% em `lexppp` eleva $math4$ em aproximadamente

$$9{,}01 \times 0{,}10 = 0{,}901$$

ponto percentual.

(ii) Sim. O coeficiente de `lexppp` cai de 9,01 para 1,93 e perde significância estatística. O coeficiente de `free` também cai bastante em magnitude. Ja `lmedinc` fica muito mais negativo e passa a parecer estatisticamente importante, enquanto `pctsgle` aumenta em magnitude e também ganha significância. Isso sugere forte correlação de `read4` com as demais variáveis e que ela esta capturando grande parte da variação comum no desempenho escolar.

(iii) **Um R^2 maior não significa automaticamente um modelo melhor para causalidade**. A segunda equação prediz melhor porque usa uma variável muito próxima do próprio desempenho em matemática, mas isso não a torna mais útil para medir o efeito causal dos gastos. Se o objetivo e estimar esse efeito, a primeira equação e preferível, mesmo com menor R^2 ajustado.

3. (6.3, (Wooldridge, 2023)) Utilizando os dados contidos no arquivo `RDCHEM`, a seguinte equacao foi obtida por MQO:

$$\widehat{rdintens} = 2{,}613 + 0{,}00030\, sales - 0{,}0000000070\, sales^2$$
$$(0{,}429) \qquad (0{,}00014) \qquad (0{,}0000000037)$$
$$n = 32,\ R^2 = 0{,}1484.$$

(i) Em que ponto o efeito marginal de `sales` sobre `rdintens` se torna negativo?

(ii) Você manteria o termo quadrático no modelo? Explique.

(iii) Defina `salesbil` como vendas expressas em bilhões de dólares: $salesbil = sales/1.000$. Reescreva a equação com `salesbil` e $salesbil^2$ como as variáveis independentes. Certifique-se de descrever os erros padrão e o R-quadrado. [Dica: Observe que $salesbil^2 = sales^2/(1.000)^2$.]

(iv) Com o proposito de reportar os resultados, qual equação você prefere?

R:

(i) O efeito marginal e

$$\frac{\partial \widehat{rdintens}}{\partial sales} = 0{,}00030 - 2(0{,}0000000070)\, sales.$$

Igualando a zero,

$$0{,}00030 = 0{,}000000014\, sales$$

e portanto

$$sales \approx 21428{,}57.$$

Como `sales` esta em milhões de dólares, isso corresponde a cerca de 21,43 bilhões de dólares.

(ii) O termo quadrático tem estatística t de aproximadamente

$$\frac{-0{,}0000000070}{0{,}0000000037} \approx -1{,}89.$$

Assim, ele não e claramente significante a 5%, embora haja alguma evidencia de curvatura a 10%. Eu o manteria apenas se quisesse permitir explicitamente retornos decrescentes; caso contrario, ha argumento para um modelo mais simples.

(iii) Como $sales = 1000\, salesbil$ e $sales^2 = 1000000\, salesbil^2$, a equação fica

$$\widehat{rdintens} = 2{,}613 + 0{,}30\, salesbil - 0{,}0070\, salesbil^2.$$

Os erros padrão também mudam de escala:

$$(0{,}429) \qquad (0{,}14) \qquad (0{,}0037).$$

O R^2 permanece

$$R^2 = 0{,}1484.$$

(iv) Para reportar os resultados, eu prefiro a equação com `salesbil`, pois os coeficientes ficam muito mais legíveis e fáceis de interpretar, sem alterar ajuste, sinais ou significância.

4.* (5.5, (Wooldridge, 2023)) O histograma a seguir foi criado usando-se a variável *score* do arquivo `ECONMATH`. Foram usadas trinta divisões para cria-lo, e a altura de cada célula e a proporção de observações dentro do intervalo correspondente. A distribuição normal de melhor ajuste isto é, usando a media amostral e o desvio padrão amostral foi sobreposta no histograma.

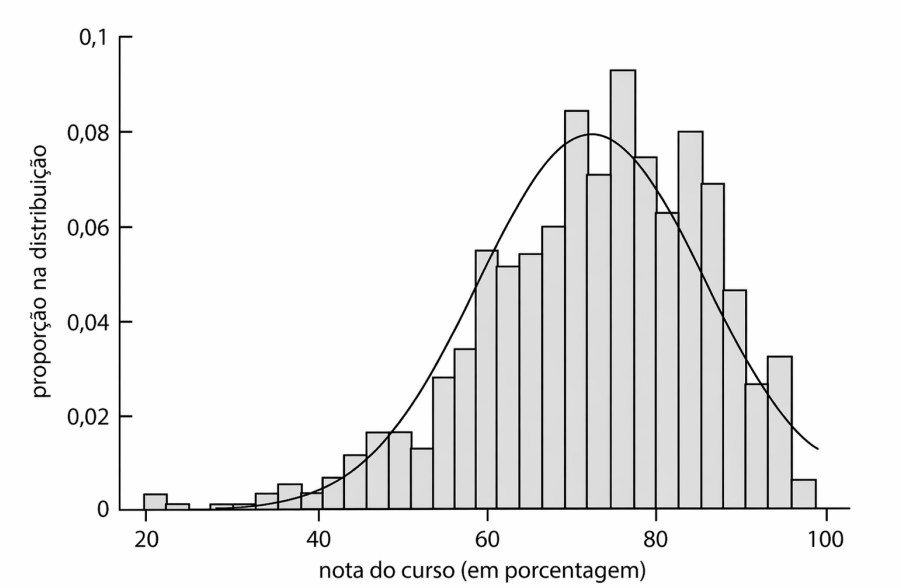

(i) Se você usar a distribuição normal para estimar a probabilidade de *score* superar 100, a resposta seria zero? Por que sua resposta contradiz a hipótese de uma distribuição normal de *score*?

(ii) Explique o que esta acontecendo na parte esquerda do histograma. A distribuição normal se ajusta bem a parte esquerda do gráfico?

R:

(i) Não. Se *score* fosse exatamente normal, haveria sempre probabilidade positiva de observar valores acima de 100, porque a distribuição normal tem suporte em toda a reta real. Isso contradiz o fato de que notas em porcentagem são naturalmente limitadas superiormente por 100.

(ii) A distribuição apresenta **assimetria a esquerda**: a maior parte das notas esta entre 60 e 90, mas existe uma cauda mais longa de notas baixas. Na parte esquerda do histograma, vemos mais massa em valores baixos do que uma normal ajustada sugeriria. Portanto, a normal não se ajusta tao bem a cauda esquerda.

5.* (6.C9, (Wooldridge, 2023))[1]. O conjunto de dados `NBASAL` contem informacoes salariais e estatisticas carreira de 269 jogadores da National Basketball Association (NBA).

(i) Estime um modelo que relacione pontos por jogo (*points*) aos anos na liga (*exper*), *age* e *years* jogando na universidade (*coll*). Inclua um termo quadrático em *exper*; as outras variáveis devem aparecer em nível. Registre os resultados na forma usual.

(ii) Mantendo os anos na universidade e a idade fixos, por qual valor de experiencia o ano seguinte de experiencia reduziria os pontos por jogo? Isso faz sentido?

(iii) Por que você acha que *coll* tem um coeficiente negativo e estatisticamente significativo? (Dica: Jogadores da NBA podem ser convocados antes de terminar suas carreiras universitárias e ate mesmo diretamente do Ensino Médio.)

(iv) Adicione um termo quadrático em *age* a equação. Ele e necessário? O que isso parece sugerir em relação aos efeitos de idade, uma vez que experiencia e educação estão controladas?

(v) Agora faca a regressão de log(`wage`) sobre `points`, `exper`, `exper`^{2}, `age` e `coll`. Relate os resultados de forma usual.

(vi) Teste se `age` e `coll` são conjuntamente significativos na regressão do item (v). O que isso implica em relação a idade e educação terem efeitos separados sobre salario, uma vez que produtividade e tempo de serviço são levados em conta?

Referências

Wooldridge, J. M. (2023). *Introdução à Econometria: Uma Abordagem Moderna*. Cengage Learning, São Paulo, 4 edition.

[1]Esta e uma questão computacional. Para instalar o `R` e o `RStudio` veja o passo a passo aqui: https://rstudio-education.github.io/hopr/starting.html. Caso tenha duvidas quanto a linguagem, consulte o material disponibilizado no Moodle, e recomendo também o seguinte material de introdução ao `R`: https://fhnishida.netlify.app/project/rec2301/sec2/