

Lista 9 Gabarito - Econometria I - 2026

Prof: André Luiz Pereira Mancha

Monitor: Tuffy Licciardi Issa

1. (7.10, (Wooldridge, 2023)) Para uma criança i que mora em determinada região de ensino, defina *voucher* como uma variável *dummy* igual a um se a criança foi selecionada para participar de um programa de bolsas de estudos em uma escola, e defina *score* como a nota da criança em um exame padronizado subsequente. Suponha que a variável de participação, *voucher*, seja completamente aleatorizada para que ela seja independente tanto dos fatores observados quanto dos não observados que possam afetar a nota do teste de avaliação.
 - (i) Se você executar uma regressão simples de *score* sobre *voucher*, usando uma amostra aleatória de tamanho n , o estimador de MQO produziria um estimador não viesado do efeito do programa de bolsas de estudos?
 - (ii) Suponha que você possa coletar informações adicionais sobre perfis familiares, tais como renda familiar, estrutura familiar (por exemplo, se a criança mora com os dois pais) e nível de escolaridade dos pais. Você precisaria controlar esses fatores para obter um estimador não viesado dos efeitos do programa de bolsas de estudos? Explique.
 - (iii) Por que você precisaria incluir as variáveis de perfis familiares na regressão? Existe alguma situação em que você não incluiria essas variáveis?

R:

- (i) Sim. Como *voucher* foi completamente aleatorizada, ela é independente dos fatores observados e não observados que afetam *score*. Assim, na regressão simples, a condição de exogeneidade é satisfeita e o estimador de MQO é não viesado para o efeito causal médio do programa.
- (ii) Não para obter não viesamento. A aleatorização já garante identificação causal sem esses controles. Ainda assim, incluir variáveis familiares pode reduzir a variância do erro e melhorar a precisão das estimativas.
- (iii) O principal motivo para incluí-las é ganho de precisão. Se renda, estrutura familiar e escolaridade dos pais explicam parte importante de *score*, então controlá-las reduz a variância residual. Uma situação em que eu poderia não incluí-las é quando a aleatorização é confiável e essas covariáveis pouco acrescentam em termos de precisão, ou quando coletá-las é custoso e pouco informativo.

2. (7.9, (Wooldridge, 2023)) Seja d uma variável *dummy* (binária) e z uma variável quantitativa. Considere o modelo

$$y = \beta_0 + \delta_0 d + \beta_1 z + \delta_1 d \cdot z + u;$$

essa é uma versão geral de um modelo com uma interação entre uma variável *dummy* e uma variável quantitativa. [Um exemplo está na equação (7.17).]

- (i) Como isso não alterará nada importante, defina o erro com valor zero, $u = 0$. Então, quando $d = 0$, podemos escrever o relacionamento entre y e z como a função $f_0(z) = \beta_0 + \beta_1 z$. Escreva essa mesma relação quando $d = 1$, em que você deve usar $f_1(z)$ no lado esquerdo para denotar a função linear de z .
- (ii) Considerando $\delta_1 \neq 0$ (o que significa que as duas não são paralelas), demonstre que o valor de z^* é tal que $f_0(z^*) = f_1(z^*)$ e $z^* = -\delta_0/\delta_1$. Esse é o ponto no qual as duas linhas se cruzam [como na Figura 7.2(b)]. Demonstre que z^* será positivo se, e somente se, δ_0 e δ_1 tiverem sinais opostos.
- (iii) Usando os dados contidos no arquivo **TWOYEAR**, a seguinte equação poderá ser estimada:

$$\widehat{\log(wage)} = 2,289 - 0,357 \text{ female} + 0,050 \text{ totcoll} + 0,030 \text{ female} \cdot \text{totcoll}$$

$$(0,011) \quad (0,015) \quad (0,003) \quad (0,005)$$

$$n = 6,763, R^2 = 0,202$$

em que todos os coeficientes e erros padrão foram arredondados com três casas decimais. Usando essa equação, encontre o valor de *totcoll* de tal forma que os valores previstos de $\log(wage)$ sejam os mesmos tanto para homens quanto para mulheres.

- (iv) Com base na equação do item (iii), as mulheres podem, de forma realística, obter educação superior de modo que seus ganhos alcancem os dos homens? Explique.

R:

- (i) Quando $d = 1$,

$$y = \beta_0 + \delta_0 + (\beta_1 + \delta_1)z,$$

de modo que

$$f_1(z) = (\beta_0 + \delta_0) + (\beta_1 + \delta_1)z.$$

- (ii) O ponto de cruzamento satisfaz

$$f_0(z^*) = f_1(z^*).$$

Logo,

$$\beta_0 + \beta_1 z^* = \beta_0 + \delta_0 + (\beta_1 + \delta_1) z^*.$$

Cancelando os termos comuns,

$$0 = \delta_0 + \delta_1 z^*,$$

e portanto

$$z^* = -\frac{\delta_0}{\delta_1}.$$

Além disso, $z^* > 0$ se, e somente se, δ_0 e δ_1 tiverem sinais opostos.

(iii) Para homens ($female = 0$),

$$\widehat{\log(wage)} = 2,289 + 0,050 \text{ totcoll}.$$

Para mulheres ($female = 1$),

$$\widehat{\log(wage)} = 2,289 - 0,357 + (0,050 + 0,030) \text{ totcoll} = 1,932 + 0,080 \text{ totcoll}.$$

Igualando as duas expressões:

$$2,289 + 0,050 \text{ totcoll} = 1,932 + 0,080 \text{ totcoll}.$$

Assim,

$$0,357 = 0,030 \text{ totcoll} \Rightarrow \text{ totcoll} = 11,9.$$

(iv) Em termos práticos, não parece muito realístico. O valor de 11,9 anos de ensino superior é muito alto: corresponde a uma trajetória muito longa após o ensino médio. Portanto, embora o modelo permita esse cruzamento, ele parece ocorrer em uma faixa pouco plausível da amostra.

3. (7.11, (Wooldridge, 2023)) As equações a seguir foram estimadas usando os dados do arquivo **ECONMATH**, com erros padrão registrados abaixo dos coeficientes. A nota média da classe, medida como porcentagem, é de cerca de 72,2; exatamente 50% dos estudantes são do sexo masculino; e a média de *colgpa* (nota média no início do semestre) é de cerca de 2,81.

$$\widehat{score} = 32,31 + 14,32 \text{ colgpa}$$

$$(2,00) \quad (0,70)$$

$$n = 856, R^2 = 0,329, \bar{R}^2 = 0,328$$

$$\widehat{score} = 29,661 + 3,83 \text{ male} + 14,57 \text{ colgpa}$$

$$(2,04) \quad (0,74) \quad (0,69)$$

$$n = 856, R^2 = 0,349, \bar{R}^2 = 0,348$$

$$\widehat{score} = 30,36 + 2,47 \text{ male} + 14,33 \text{ colgpa} + 0,479 \text{ male} \cdot \text{colgpa}$$

$$(2,86) \quad (3,96) \quad (0,98) \quad (1,383)$$

$$n = 856, R^2 = 0,349, \bar{R}^2 = 0,347$$

$$\widehat{score} = 30,36 + 3,82 \text{ male} + 14,33 \text{ colgpa} + 0,479 \text{ male} \cdot (\text{colgpa} - 2,81)$$

$$(2,86) \quad (0,74) \quad (0,98) \quad (1,383)$$

$$n = 856, R^2 = 0,349, \bar{R}^2 = 0,347$$

- (i) Interprete o coeficiente sobre *male* na segunda equação e construa um intervalo de confiança de 95% para β_{male} . Esse intervalo de confiança exclui zero?
- (ii) Na segunda equação, por que a estimativa de *male* é tão imprecisa? Devemos agora concluir que não existem diferenças de gênero em notas depois de controlar *colgpa*? [Dica: Você pode querer calcular a estatística F da hipótese nula de que não há diferença de gênero no modelo com interação.]

R:

- (i) Na segunda equação, o coeficiente de *male* é 3,83. Portanto, mantendo *colgpa* fixa, homens obtêm em média 3,83 pontos a mais do que mulheres. O intervalo de confiança de 95% é

$$3,83 \pm 1,96(0,74),$$

isto é,

$$[2,38, 5,28].$$

Como zero não pertence a esse intervalo, ele exclui zero.

- (ii) A dica do enunciado sugere que a preocupação real está no modelo com interação. Nele, o coeficiente de *male* sem centragem mede a diferença de gênero quando *colgpa* = 0, um valor muito distante da média observada (2,81). Por isso o erro padrão fica grande nessa parametrização. Não devemos concluir automaticamente que não há diferenças de gênero apenas porque um coeficiente isolado parece impreciso. O teste correto, no modelo com interação, é a hipótese conjunta

$$H_0 : \beta_{male} = 0 \quad \text{e} \quad \beta_{male \cdot colgpa} = 0.$$

Portanto, a conclusão deve se basear em um teste F conjunto, e não apenas no t de um coeficiente.

4. (7.12, (Wooldridge, 2023)) Consideremos o Exemplo 7.11, em que, antes de calcular a interação entre a raça/etnicidade de um jogador e a composição racial da cidade, centramos as variáveis de composição da cidade sobre as médias amostrais, *percblck* e *perchisp* (que são, aproximadamente, 16,55 e 10,82, respectivamente). A equação estimada resultante é

$$\begin{aligned}
 \widehat{\log(\text{salary})} = & 10,23 + 0,0673 \text{ years} + 0,0089 \text{ gamesyr} + 0,00095 \text{ bavg} + 0,146 \text{ hrunsyr} \\
 & (2,18) \quad (0,0129) \quad (0,0034) \quad (0,00151) \quad (0,164) \\
 & + 0,0045 \text{ rbisyr} + 0,0072 \text{ runsyr} + 0,0011 \text{ fldperc} + 0,0075 \text{ allstar} \\
 & (0,0076) \quad (0,0046) \quad (0,0021) \quad (0,0029) \\
 & + 0,0080 \text{ black} + 0,0273 \text{ hispan} + 0,0125 \text{ black} \cdot (\text{percblck} - \overline{\text{percblck}}) \\
 & (0,0840) \quad (0,1084) \quad (0,0050) \\
 & + 0,0201 \text{ hispan} \cdot (\text{perchisp} - \overline{\text{perchisp}}) \\
 & (0,0098) \\
 & n = 330, R^2 = 0,638
 \end{aligned}$$

- (i) Por que os coeficientes de *black* e *hispan* são agora tão diferentes daqueles que foram reportados na equação (7.19)? Especificamente, como se pode interpretar esses coeficientes?
- (ii) O que você pensa do fato de nem *black* nem *hispan* serem estatisticamente significantes na equação acima?
- (iii) Ao comparar a equação acima com a equação (7.19), mais alguma coisa mudou? Por que sim ou por que não?

R:

- (i) Eles mudam porque, ao centrar *percblck* e *perchisp*, os coeficientes de *black* e *hispan* passam a medir o efeito de raça/etnia quando a composição racial da cidade está em seu valor médio amostral. Portanto, 0,0080 é o diferencial salarial estimado para jogadores negros em uma cidade com *percblck* média, e 0,0273 é o diferencial para jogadores hispânicos em uma cidade com *perchisp* média.
- (ii) Isso não é especialmente preocupante. Como os efeitos de raça/etnia dependem da composição racial da cidade, o efeito avaliado exatamente na média pode ser pequeno e impreciso, mesmo quando os termos de interação são relevantes. O ponto central é que o diferencial não é constante: ele varia com o contexto da cidade.

- (iii) Sim e não. Os coeficientes de *black* e *hispan* mudam de interpretação, e o intercepto também muda. Mas os valores ajustados, os resíduos, o R^2 , o ajuste geral e os coeficientes das interações permanecem essencialmente os mesmos. Em outras palavras, houve uma reparametrização, não uma mudança substantiva do modelo.

5.* (7.C14, (Wooldridge, 2023)) Use os dados do arquivo CHARITY para responder a essa questão. A variável *respond* é uma variável *dummy* igual a um se a pessoa respondeu com uma contribuição à mais recente correspondência enviada por uma organização de caridade. A variável *resplast* é uma variável *dummy* igual a um se a pessoa respondeu ao envio anterior, *avggift* é a média de doações passadas (em florins holandeses), e *propresp* é a proporção de vezes que a pessoa respondeu às correspondências anteriores.

- (i) Estime um modelo de probabilidade linear relacionando *respond* a *resplast* e *avggift*. Registre os resultados na forma usual e interprete o coeficiente sobre *resplast*.
- (ii) O valor médio das doações passadas parece afetar a probabilidade de resposta?
- (iii) Adicione a variável *propresp* ao modelo e interprete seu coeficiente. [Tenha cuidado aqui: o aumento de uma unidade em *propresp* é a maior mudança possível.]
- (iv) O que aconteceu com o coeficiente de *resplast* quando *propresp* foi adicionada à regressão? Isso faz sentido?
- (v) Adicione *mailsyear*, o número de correspondências enviadas por ano, ao modelo. Quão grande é seu efeito estimado? Por que essa pode não ser uma boa estimativa do efeito causal dos envios sobre as respostas?

Referências

Wooldridge, J. M. (2023). *Introdução à Econometria: Uma Abordagem Moderna*. Cengage Learning, São Paulo, 4 edition.